ESTUDO DE CASO DE RECOLHA DE INFORMAÇÃO

Processamento de Linguagem Natural e LLM

Abstract

Design de um classificador de géneros de livros com base nas suas sinopses.

Diogo Mendes

20251612

Contents

1. Contexto do Estudo 2
2. Metodologia 2
2.1. Recolha de Dados 2
2.2. Pré-Processamento 3
2.2.1 Limpeza genérica dos dados 4
2.2.2 representação do texto 5
2.2.2.1 TF-IDF para inglês 7
2.2.2.2 SBERT multilingue 8
2.2.3 Representação das classes 9
2.3 Modelação e Treino 10
2.3.1 Regressão Logística 12
2.3.2 SGBoost 12
2.3.3 SVM 13
2.3.4 Vulnerabilidades identificadas no treino 14
3.4 Teste e avaliação dos modelos 15
3.4.1. Impacto do Threshold 18
3.4.2. Accuracy 18
3.4.3. Hamming Loss 18
3.4.4 Accuracy, recall e F1 score 18
3.4.5 Comparação entre representações de texto 19
3.5 Utilização dos modelos 20
4 Conclusões finais e trabalho futuro 22
5 Tecnologias Utilizadas 23
6 Anexos 23

1. Contexto do Estudo

O *Processamento de Linguagem Natural (NLP)* permite automatizar a análise de textos e a extração de informação útil. Uma aplicação relevante é a **classificação de textos em categorias**, incluindo cenários multi-label, onde um texto pode pertencer a mais do que uma categoria ao mesmo tempo.

O objetivo deste estudo foi **desenvolver um classificador capaz de prever múltiplos géneros literários a partir da descrição de um livro**, combinando técnicas clássicas de NLP com embeddings contextuais modernos. Esta tarefa é importante em sistemas de recomendação, organização de bibliotecas digitais e motores de busca literários.

O trabalho segue as fases descritas na unidade curricular, garantindo a aplicação prática de conceitos teóricos.

Este trabalho tem como objetivos de aprendizagem:

- Recolher e preparar um conjunto de dados textual
- Compreender a importância do pré-processamento em NLP
- Treinar diferentes modelos de classificação, incluindo abordagens clássicas e modernas
- Avaliar os modelos utilizando métricas apropriadas para problemas de classificação
- Comparar resultados e discutir limitações

2. Metodologia

O projeto foi desenvolvido seguindo as seguintes fases:

2.1. Recolha de Dados

Foi recolhido o dataset “Goodreads' Best Books Ever” disponível no Kaggle, que entre os vários campos, destacam-se a Descrição textual (book_desc) e os géneros (genres)

Fonte: https://www.kaggle.com/datasets/meetnaren/goodreads-best-books

book_authors	book_desc	book_edition	book_form	book_isbn	book_pages	book_rating	book_rat	book_revi	book_title	genres	imag
Suzanne Collins	Winning will make you famous. Losing mea		Hardcover	9.78044E+12	374 pages	4.33	5519135	160706	The Hunger Games	Young Adult|Fiction|Science Fiction|Dystopia|Fa	https
J.K. Rowling|Mary GrandPré	There is a door at the end of a silent corrido	US Edition	Paperback	9.78044E+12	870 pages	4.48	2041594	33264	Harry Potter and the Order of the Phoenix	Fantasy|Young Adult|Fiction	https
Harper Lee	The unforgettable novel of a childhood in a	50th Anniversary	Paperback	9.78006E+12	324 pages	4.27	3745197	79450	To Kill a Mockingbird	Classics|Fiction|Historical|Historical Fiction|Ac	https
Jane Austen|Anna Quindlen|Mrs. Olip	È cosa ormai risaputa che a uno scapolo i	Modern Library Classics, USA / CAN	Paperback	9.78068E+12	279 pages	4.25	2453620	54322	Pride and Prejudice	Classics|Fiction|Romance	https
Stephenie Meyer	About three things I was absolutely positive.		Paperback	9.78032E+12	498 pages	3.58	4281268	97991	Twilight	Young Adult|Fantasy|Romance|Paranormal|Van	https
Markus Zusak	Trying to make sense of the horrors of World	First American Edition (US / CAN)	Hardcover	9.78038E+12	552 pages	4.36	1485632	100821	The Book Thief	Historical|Historical Fiction|Fiction|Young Adult	https
C.S. Lewis|Pauline Baynes	Journeys to the end of the world, fantastic cr	Reissue Edition	Paperback	9.78007E+12	767 pages	4.25	437829	9439	The Chronicles of Narnia	Fantasy|Classics|Fiction|Young Adult|Childrens	https
George Orwell	مزرعة الحيوانات هي رائعة جورج أورويل الخالدة، اختا		Paperback	9.78045E+12	122 pages	3.9	2235084	42156	Animal Farm	Classics|Fiction|Science Fiction|Dystopia|Fanta	https
Margaret Mitchell	Gone with the Wind is a novel written by Ma		Paperback	9.78045E+12	1037 pages	4.29	969181	17452	Gone with the Wind	Classics|Historical|Historical Fiction|Fiction|Ro	https
J.R.R. Tolkien	الجزء الثالث من ملحمة جيه أر أر تولكين الرائعة سيد الخا	Hobbit Movie Tie-in Boxed set	Mass Market	9.78035E+12	1728 pages	4.59	99793	1652	J.R.R. Tolkien 4-Book Boxed Set: The Hobb	Fantasy|Fiction|Classics	https
John Green	Despite the tumor-shrinking medical miracl		Hardcover	9.78053E+12	313 pages	4.24	2881648	147270	The Fault in Our Stars	Young Adult|Fiction|Romance|Contemporary	https
Douglas Adams	Seconds before the Earth is demolished to m		Paperback	9.78035E+12	193 pages	4.21	1155911	23919	The Hitchhiker's Guide to the Galaxy	Science Fiction|Fiction|Humor|Fantasy|Classics	https
Shel Silverstein	"Once there was a tree....and she loved a litt		Hardcover	9.78006E+12	64 pages	4.37	789681	15694	The Giving Tree	Childrens|Childrens|Picture Books|Classics|Fict	https
Emily Brontë|Richard J. Dunn|David Ti	You can find the redesigned cover of this ed	Fourth Edition	Paperback	9.78039E+12	464 pages	3.84	1121100	29400	Wuthering Heights	Classics|Fiction|Romance|Literature	https
Dan Brown	An ingenious code hidden in the works of Le		Paperback	9.78031E+12	481 pages	3.81	1668594	43699	The Da Vinci Code	Fiction|Mystery|Thriller	https
Arthur Golden	A literary sensation and runaway bestseller	Large Print	Hardcover	9.78074E+12	434 pages	4.09	1525851	27168	Memoirs of a Geisha	Fiction|Historical|Historical Fiction|Romance|Hi	https
Lewis Carroll|John Tenniel|Martin Gar	" I can't explain myself, I'm afraid, sir," said		Mass Market	9.78045E+12	239 pages	4.07	411153	9166	Alice's Adventures in Wonderland & Thro	Classics|Fantasy|Fiction|Childrens	https
Oscar Wilde|Jeffrey Eugenides	Written in his distinctively dazzling manner,	Modern Library Classics	Paperback	9.78038E+12	367 pages	4.06	775701	22938	The Picture of Dorian Gray	Fiction|Classics|Horror|Fantasy|Literature|Goth	https
Victor Hugo|Lee Fahnestock|Norman	Introducing one of the most famous charac		Mass Market	9.78045E+12	1463 pages	4.15	591874	13063	Les Misérables	Classics|Fiction|Historical|Historical Fiction|Lit	https
Veronica Roth	In Beatrice Prior's dystopian Chicago world,		Paperback	9.78006E+12	487 pages	4.22	2493519	104329	Divergent	Young Adult|Science Fiction|Dystopia|Fiction|Fa	https
Charlotte Brontë|Michael Mason	Fiery love, shocking twists of fate, and tragic	Penguin Classics	Paperback	9.78014E+12	507 pages	4.11	1381404	34670	Jane Eyre	Classics|Fiction|Romance|Historical|Historical	https
William Shakespeare|Barbara A. Mow	In Romeo and Juliet, Shakespeare creates a	New Folger edition	Mass Market	9.78074E+12	283 pages	3.74	1818262	16442	Romeo and Juliet	Classics|Plays|Fiction|Romance|Academic|Sch	https
William Golding	At the dawn of the next world war, a plane cr	Penguin Great Books of the 20th Centur	Paperback	9.78014E+12	182 pages	3.66	1840595	30634	Lord of the Flies	Classics|Fiction|Young Adult|Academic|School|	https
Paulo Coelho|Alan R. Clarke|Özdemir	Paulo Coelho's masterpiece tells the mystic		Paperback	9.78006E+12	197 pages	3.84	1644387	63861	The Alchemist	Fiction|Classics|Fantasy|Philosophy|Novels|Sp	https
Fyodor Dostoyevsky|David McDuff	Raskolnikov, an impoverished student livin	Penguin Classics	Paperback	9.78014E+12	671 pages	4.2	507522	14496	Crime and Punishment	Classics|Fiction|Cultural|Russia|Literature|Liter	https
Orson Scott Card	Andrew "Ender" Wiggin thinks he is playing	Author's Definitive Edition, Revised mar	Mass Market	9.78081E+12	324 pages	4.3	965351	40289	Ender's Game	Science Fiction|Fiction|Young Adult|Fantasy	https
Stephen Chbosky	The critically acclaimed debut novel from St		Paperback	9.78067E+12	213 pages	4.2	1063711	50846	The Perks of Being a Wallflower	Young Adult|Fiction|Contemporary	https
Cassandra Clare|Franca Fritz|Heinric	When fifteen-year-old Clary Fray heads out t		Hardcover	9.78142E+12	485 pages	4.11	1383479	55446	City of Bones	Fantasy|Young Adult|Fantasy|Paranormal|Roma	https
Kathryn Stockett	Be prepared to meet three unforgettable wo		Hardcover	9.7804E+12	465 pages	4.46	1790905	80741	The Help	Fiction|Historical|Historical Fiction|Historical|Ar	https
F. Scott Fitzgerald	Alternate Cover Edition ISBN: 0743273567 (IS	US / CAN	Paperback		180 pages	3.9	3141842	56953	The Great Gatsby	Classics|Fiction|Academic|School|Literature|Hi	https
Audrey Niffenegger	A funny, often poignant tale of boy meets gir	Special Edition	ebook		500 pages	3.96	1408080	45153	The Time Traveler's Wife	Fiction|Romance|Fantasy|Science Fiction|Time T	https
E.B. White|Garth Williams|Rosemary	This beloved book by E. B. White, author of S	Full Color Edition	Paperback	9.78006E+12	184 pages	4.16	1199733	14938	Charlotte's Web	Classics|Childrens|Fiction	https
L.M. Montgomery	As soon as Anne Shirley arrives at the snug		Paperback	9.78045E+12	320 pages	4.24	599365	16797	Anne of Green Gables	Classics|Fiction|Young Adult|Childrens|Historic	https
John Steinbeck	The compelling story of two outsiders strivir	Steinbeck Centennial Edition, US / CAN	Paperback	9.78014E+12	112 pages	3.85	1662561	27999	Of Mice and Men	Classics|Fiction|Academic|School|Literature|Hi	https
Bram Stoker|Nina Auerbach|David J. S	You can find an alternative cover edition for	Norton Critical Edition	Paperback	9.78039E+12	488 pages	3.98	775448	19726	Dracula	Classics|Horror|Fiction|Fantasy|Paranormal|Va	https

---

2.2. Pré-Processamento

Os dados foram carregados e representados em estruturas tabulares disponibilizadas pela biblioteca “pandas”.

```python
import pandas as pd
df = pd.read_csv("tp1_dataset.csv", usecols=["book_desc", "genres"])

print(df.shape)
print(df.dtypes)
```

✓ 3.6s

```
(54301, 2)
book_desc    str
genres       str
dtype: object
```

Após uma breve análise às descrições, foi possível concluir:

- O número de descrições (52970) não corresponde ao número de linhas do dataset (54301), ou seja, existem livros sem descrição, o que devem ser retirados;
- O numero de descrições únicas (51781) não corresponde ao total de descrições (52970), o que podemos concluir que existem descrições duplicadas;
- Descrições em múltiplas líguas e até em outros sistemas de escrita além do Alfabético, como por exemplo em Abjad (Árabe);
- Algumas descrições continham caracteres de indentação ou a própria representação desses caracteres em texto, como o carriage return (\r) e o line feeding (\n), o que não acrescenta valor semântico ao texto e pode prejudicar o processo de tokenização, gerando embeddings ligeiramente diferentes para a mesma sentença.

```
print(df["book_desc"].head(10))
print(df["book_desc"].describe())
```

✓ 0.0s

```
0    Winning will make you famous. Losing means cer...
1    There is a door at the end of a silent corrido...
2    The unforgettable novel of a childhood in a sl...
3    «È cosa ormai risaputa che a uno scapolo in po...
4    About three things I was absolutely positive.F...
5    Trying to make sense of the horrors of World W...
6    Journeys to the end of the world, fantastic cr...
7    مزرعة الحيوانات هي رائعة جورج أورويل الخالدة.....
8    Gone with the Wind is a novel written by Marga...
9    ... لجزء الثالث من ملحمة جيه أر أر تولكين الرائعة
Name: book_desc, dtype: str
count                                               52970
unique                                              51781
top       ...هذه هي طبعة "دار الفكر - بيروت" وهي آخر طبعة ع
freq                                                   38
Name: book_desc, dtype: object
```

```
repeated = df.groupby(["book_desc"]).size().reset_index(name="count")
repeated = repeated[repeated["count"] > 1]

print(repeated)
```

✓ 0.0s

```
                                          book_desc  count
238    \r\n\r\n\r\nBased on the true story of a forgo...      2
557    \r\n\r\nWar has erupted in the Banished Lands ...      2
926     Until now, he's existed only in her dreams -b...      2
956     milk and honey  is a collection of poetry and...      2
1135   "As Gregor Samsa awoke one morning from uneasy...      2
...                                                  ...    ...
51258  "Did you ever hear the Tragedy of Darth Plague...      2
51304  "Her knees were weak and if not for that marbl...      2
51461  "Our Dragon doesn't eat the girls he takes, no...      2
51640  „Als ich zum ersten Mal in deine Augen sah, wu...      2
51649  „Dievų miškas" — memuarinis lietuvių rašytojo ...      2

[926 rows x 2 columns]
```

2.2.1 Limpeza genérica dos dados

Para resolver as inconsistências apresentadas foi então realizado um processo de limpeza dos dados, removendo os duplicados e nulos, removendo caracteres sem valor semântico e normalizando os textos para Unicode, facilitando a interpretação dos textos, especialmente em sistemas de escrita distintos.

```python
print(df.shape)

import re
import unicodedata

def clean_text(text):
    # if the text is NaN (missing value), return it as is to avoid processing
    if pd.isna(text):
        return text
    text = str(text)
    # remove carriage returns and line feeds
    text = re.sub(r"(\\[rn]|[\r\n])+", " ", text)
    # replace multiple whitespace characters with a single space and trim leading/trailing whitespace
    text = re.sub(r"\s+", " ", text).strip()
    # if the resulting text is empty after cleaning, return None to indicate missing value
    if text == "":
        return None
    # normalize to unicode to ensure consistent representation of characters
    text = unicodedata.normalize("NFKC", text)
    return text

df["book_desc_clean"] = df["book_desc"].apply(clean_text)
# drop null values from ratings and descriptions
df = df.dropna(subset=["book_desc_clean", "book_rating"])
# drop duplicated descriptions
df = df.drop_duplicates(subset="book_desc_clean", keep="last")
# reset index after dropping rows to avoid issues with indexing later on
df = df.reset_index(drop=True)

print(df.shape)
```

✓ 4.4s

```
(54301, 2)
(51754, 3)
```

2.2.2 representação do texto

Após a identificação de existência das múltiplas linguagens, verificou-se que não existia uma coluna no dataset que identifica-se a linguagem, por isso foi feito um estudo sobre as linguagens das descrições e o número de descrições por linguagem com elevado grau de confiança.

Para este estudo foi usado a biblioteca “fast-textdetect” (https://github.com/LlmKira/fast-langdetect) baseado no “fasttext” desenvolvido pelo Facebook que usa um modelo pré-treinado capaz de identificar 157 linguagens (https://github.com/facebookresearch/fastText)

```python
from fast_langdetect import detect

lang_confidence_threshold = 0.7

def detect_language(text):
    result = detect(str(text), model='lite', k=1)
    return result[0]["lang"], result[0]["score"]

df[["lang", "lang_confidence"]] = df["book_desc_clean"].apply(lambda x: pd.Series(detect_language(x)))
df["high_conf"] = df["lang_confidence"] > lang_confidence_threshold

languages_stats = df.groupby("lang").agg(
    high_confidence=("high_conf", "sum"),
    total=("lang", "size")
)
print(languages_stats.to_string())
```

✓ 3.9s

```
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\tqdm\auto.py:21: TqdmWarning: IProgr
  from .autonotebook import tqdm as notebook_tqdm
      high_confidence  total
lang
af                  0      1
ar                680    695
arz                 1      2
azb                 0      1
bg                 71     77
bn                 26     26
bs                  0      1
ca                  8     12
ceb                 0      3
cs                105    108
da                 41     68
de                574    641
el                 94     95
en              39383  42674
eo                  0      2
es                828    891
et                 16     21
fa                126    135
fi                 90     94
fr                555    594
fy                  0      1
gl                  1      3
hi                  5      6
```

Com esta análise conclui-se que existem poucas descrições para cada linguagem à exceção de inglês, com 39383 descrições com elevada confiança de assertividade.

A existência de textos em diversas línguas levantou o problema da metodologia a aplicar par a a representação dos textos, pois os processos básicos de NLP são tipicamente monolingue, e tendo um dataset com tamanha diversidade restam apenas duas soluções:

1) Utilizar o vectorização por TF-IDF, que requer algumas estratégias adicionais de NLP para reduzir o ruído nos dados, mantendo o contexto, como a remoção de stopwords e a lematização. No entanto, esta abordagem só é viável para os livros que temos quase a certeza que estão em inglês.

2) Utilizar um modelo de embeddings multilingue pré-treinado (como o Sentence-BERT) para gerar um vetor de tamanho fixo que suporte vários idiomas e preserve a semântica. Como é quase agnóstico em relação à língua, podemos utilizar todas as descrições, 51754 registos.

Foi então decidido implementar as duas abordagens para posteriormente comparar resultados.

2.2.2.1 TF-IDF para inglês

O método TF-IDF permite a captura da relevância relativa das palavras no texto, mas para isso foi necessário processamento adicional para evitar o ruído nos dados.

Seguindo então os seguintes passos:

- remoção de pontuação
- remoção de stopwords de inglês
- lematização das palavras

Foi evitado o uso de stemming porque este tem impacto computacional no treino do modelo similar à lematização mas por vezes pode gerar confusões semânticas.

Estes passos foram realizados com recurso às funções disponibilizadas na biblioteca "nltk".

Por fim foram então convertidos os "lemas" em vectores usando a técnica TF-IDF

```python
from sklearn.feature_extraction.text import TfidfVectorizer
import nltk
from nltk.corpus import stopwords
from nltk.stem import WordNetLemmatizer
from nltk.tokenize import word_tokenize

df_english = df[(df["lang"] == "en") & (df["lang_confidence"] > lang_confidence_threshold)]

nltk.download('punkt')
nltk.download('punkt_tab')
nltk.download('stopwords')
nltk.download('wordnet')

stop_words = set(stopwords.words('english'))
lemmatizer = WordNetLemmatizer()
vectorizer = TfidfVectorizer(max_features=5000)

def preprocess(text):
    tokens = word_tokenize(text.lower())
    tokens = [
        lemmatizer.lemmatize(word)
        for word in tokens
        if word.isalpha() and word not in stop_words
    ]
    return " ".join(tokens)

lemmas = df_english["book_desc_clean"].apply(lambda x: preprocess(str(x)))

X = vectorizer.fit_transform(lemmas).toarray()
```
✓ 22.7s

2.2.2.2 SBERT multilingue

Para a abordagem de vectorização das descrições usando Sentence-BERT (SBERT) foi usado um modelo multilingue que permite manter a semântica do texto de forma (quase)independente da linguagem. O modelo é também caracterizado por ser “Distil”, que exige menos capacidade computacional quando comparado aos semelhantes não “Distil”, com a desvantagem da (teórica) menor eficácia, por gerar vetores de menor dimensão, ou seja, menos embeddings.

Os textos não sofreram mais nenhuma alteração além da descrita no capítulo 2.2.1 Limpeza genérica dos dados para não haver qualquer perda semântica e porque o próprio modelo já tem imbutido a resolução de sub-words (evitando a necessidade de lematização).

A biblioteca utilizada foi a “sentence-tranformer” e foi também utilizado a placa gráfica (com arquitectura CUDA) para acelerar o encoding.

Por fim a matriz foi guardada num documento para facilitar trabalho futuro sobre os mesmos dados, evitando correr novamente este processamento.

```python
from sentence_transformers import SentenceTransformer
import numpy as np

X_text = df['book_desc_clean'].tolist()

model_name = 'distiluse-base-multilingual-cased-v2'
model = SentenceTransformer(model_name)
X = model.encode(
    X_text,
    batch_size=64,
    show_progress_bar=True
)

np.save("book_desc_embeddings.npy", X)
```

✓ 37m 27.1s

```
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
Loading weights: 100%|▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰| 100/100 [00:00<00:00, 1649.98it/s]
Batches: 100%|▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰| 766/766 [37:07<00:00, 1.83it/s]
```

2.2.3 Representação das classes

Sendo que cada livro tinha um ou vários géneros associados, torna um problema de multi-label, o que implica um processamento adicional, isto é, não queremos apenas prever uma classe, queremos calcular a probabilidade de cada discrição pertencer a cada um dos géneros.

Para isso foi utilizado o *MultiLabelBinarizer* do “scikit-learn” para a conversão das diversas classes para uma lista de valores binários, em que cada entrada corresponde a uma classe e tem o valor de 0 ou 1, mediante se tem aquele género ou não.

```python
from sklearn.preprocessing import MultiLabelBinarizer

def preprocess_genres(approach = ""):
    if approach == "":
        approach = input("Choose approach (1 for TF-IDF, 2 for Sentence Transformers): ")

    genders = df_english["genres"].apply(lambda x: str(x).split("|")) if approach == "1" else df["genres"].apply(lambda x: str(x).split("|"))

    mlb = MultiLabelBinarizer()
    Y = mlb.fit_transform(genders)
    return Y, mlb

Y, mlb = preprocess_genres()

print(Y.shape)
print(mlb.classes_)
```

✓ 10.7s

```
(39383, 843)
['10th Century' '11th Century' '13th Century' '14th Century'
 '16th Century' '17th Century' '18th Century' '1917' '19th Century'
 '1st Grade' '20th Century' '21st Century' '2nd Grade' '40k' 'Abandoned'
 'Abuse' 'Academia' 'Academic' 'Academics' 'Action' 'Activism'
 'Adaptations' 'Adoption' 'Adult' 'Adult Fiction' 'Adventure' 'Aeroplanes'
 'Africa' 'African American' 'African American Literature'
 'African American Romance' 'African Literature' 'Agriculture' 'Aircraft'
 'Albanian Literature' 'Alchemy' 'Alcohol' 'Algeria' 'Algorithms' 'Aliens'
 'Alternate History' 'Alternative Medicine' 'Amazon' 'American'
 'American Civil War' 'American Fiction' 'American History'
 'American Revolution' 'American Revolutionary War' 'Americana' 'Amish'
 'Amish Fiction' 'Anarchism' 'Ancient' 'Ancient History' 'Angels'
 'Animal Fiction' 'Animals' 'Anime' 'Anthologies' 'Anthropology'
 'Apocalyptic' 'Archaeology' 'Architecture' 'Art' 'Art Design'
 'Art History' 'Art and Photography' 'Arthurian' 'Artificial Intelligence'
 'Asexual' 'Asia' 'Asian Literature' 'Aspergers' 'Astrology' 'Astronomy'
 'Atheism' 'Audiobook' 'Australia' 'Autobiography' 'Aviation' 'Baha I'
 'Bande Dessinée' 'Bangladesh' 'Banking' 'Banned Books' 'Baseball'
 'Basketball' 'Batman' 'Battle Of Britain' 'Bdsm' 'Beauty and The Beast'
 'Beer' 'Belgian' 'Belgium' 'Benin' 'Biblical' 'Biblical Fiction'
 'Biography' 'Biography Memoir' 'Biology' 'Birds' 'Bisexual'
 'Bizarro Fiction' 'Boarding School' 'Book Club' 'Books About Books'
 'Botswana' 'Boys Love' 'Brain' 'Brazil' 'Brewing' 'British Literature'
 'Buddhism' 'Buffy The Vampire Slayer' 'Buisness' 'Business' 'Canada'
 ...
```

2.3 Modelação e Treino

No presente trabalho, a classificação multi-label foi implementada utilizando a estratégia One-vs-Rest (OvR) através do *OneVsRestClassifier* da biblioteca “scikit-learn”.

A abordagem *One-vs-Rest* transforma um problema multi-label em vários problemas de classificação binária independentes:

- Para cada género é treinado um classificador binário:
    - Classe positiva (1): o texto pertence ao género
    - Classe negativa (0): o texto não pertence ao género

Assim são treinados tantos classificadores independentes quanto o número de géneros identificados no capítulo 2.2.3 Representação das classes.

Para efeitos de treino e teste os dados foram divididos em 2 partes (80% treino, 20% teste) de forma aleatória.

Após o término de fase de treino de cada modelo, este era gravado num ficheiro de forma a poder utilizar futuramente.

```python
from sklearn.model_selection import train_test_split
from sklearn.multiclass import OneVsRestClassifier
import joblib

def train_with(algorithm):
    # Declare X as global to ensure it is accessible within this function
    global X

    approach = input("Choose approach (1 for TF-IDF, 2 for Sentence Transformers): ")
    if approach == "2":
        # Load the precomputed embeddings from the .npy file
        X = np.load("book_desc_embeddings.npy")

    # Preprocess the genres to get the binary matrix Y
    Y, mlb = preprocess_genres(approach)

    # Split the dataset into training and testing sets (80% train, 20% test)
    X_train, X_test, Y_train, Y_test = train_test_split(
        X, Y, test_size=0.2, random_state=42
    )

    # Initialize the OneVsRestClassifier with the specified algorithm
    model = OneVsRestClassifier(algorithm)

    # Train the model on the training data
    model.fit(X_train, Y_train)
    print("Model trained successfully.")

    # Save the trained model to a file for later use
    joblib.dump(model, f"genre_classifier_{approach}_{algorithm.__class__.__name__}.joblib")
    # Save the MultiLabelBinarizer to a file for later use in decoding predictions
    joblib.dump(mlb, f"mlb_{approach}.joblib")


    return model, X_test, Y_test
```

✓ 0.0s

Para efeitos de aprendizagem e comparação de resultados foram utilizados dois algoritmos distintos:

- Regressão Logística
- SGBoost

Foi também testada a possibilidade de utilizar SVM, o que não foi possível como descrito mais adiante no capítulo 2.3.3 SVM.

2.3.1 Regressão Logística

A Regressão Logística é um algoritmo de classificação supervisionada que estima a probabilidade de uma instância pertencer a uma classe específica com base nas suas características usando uma função sigmoide.

Tem as vantagens de ser fácil de implementar e interpretar, rápido para treinar em datasets grandes, funciona bem com dados esparsos, como TF-IDF, sendo a sua principal limitação a não captura de relações complexas entre características.

```
from sklearn.linear_model import LogisticRegression

model, X_test, Y_test = train_with(LogisticRegression(max_iter=2000))
✓ 22m 18.6s
```

2.3.2 SGBoost

O SGBoost (Stochastic Gradient Boosting) é um algoritmo de ensemble baseado em árvores de decisão, que constrói iterativamente um modelo forte a partir de vários modelos fracos (decision trees).

As suas árvores são construídas sequencialmente, onde cada nova árvore corrige os erros da anterior, que difere do Random Forests com a construção independente das árvores em paralelo.

O seu comportamento estocástico introduz subamostragem dos dados e redução de overfitting.

Este algoritmo, sendo um classificador não-linear, é capaz de encontrar padrões de co-ocorrencia, por exemplo Ficção científica acontecer diversas vezes junto com Fantasia.

Teoricamente tem melhor performance em muitos problemas complexos e funciona muito bem com embeddings. No entanto é mais lento. (no caso do presente trabalho foi 7x mais lento a ser gerado em comparação com a Regressão logística, usando a representação TF-IDF dos textos e o ficheiro gerado do modelo foi 13x superior).

```python
from xgboost import XGBClassifier
import torch

device = "cuda" if torch.cuda.is_available() else "cpu"
print(f"Using device: {device}")

model, X_test, Y_test = train_with(
    XGBClassifier(
        n_estimators=500,
        max_depth=6,
        learning_rate=0.05,
        subsample=0.8,
        device=device
    )
)
```

✓ 151m 41.4s

2.3.3 SVM

O SVM (State vector machine) é um algoritmo geométrico que procura encontrar um hiperplano ótimo que separa as classes maximizando a margem entre elas.

Em teoria apresenta boa precisão entre quando comparado com os outros algoritmos não-NN com dados de elevada dimensionalidade, como no caso dos textos vetorizados, através do uso de Kernels.

No entanto após a tentativa verificou-se que, no momento da separação entre dados de treino e de teste, algumas classes não eram representadas por numa das descrições de treino, o que não é suportado pelo *CalibratedClassifierCV* da biblioteca “scikit-learn”.

A adição desta calibração seria necessária para conseguir comparar as probabilidades das classes com os restantes algoritmos, porque, o SVM é representado geometricamente com um valor real da distância ao decision boundary, e não por um valor probabilístico.

Sem a possibilidade de representação probabilística não é possível uma comparação “justa” com os restantes algoritmos e por isso foi descartada a sua utilização.

```
from sklearn.svm import LinearSVC
from sklearn.calibration import CalibratedClassifierCV

model, X_test, Y_test = train_with(CalibratedClassifierCV(LinearSVC()))
```

7.7s Python

```
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\model_selection\_split.py:813: UserWarning: The least populated class in y has only 3 members,
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\model_selection\_split.py:813: UserWarning: The least populated class in y has only 1 members,
  warnings.warn(
```

```
---------------------------------------------------------------------------
lueError                                  Traceback (most recent call last)
ll In[11], line 4
    1 from sklearn.svm import LinearSVC
    2 from sklearn.calibration import CalibratedClassifierCV
--> 4 model, X_test, Y_test = train_with(CalibratedClassifierCV(LinearSVC()))

ll In[8], line 18
   13 X_train, X_test, Y_train, Y_test = train_test_split(
   14     X, Y, test_size=0.2, random_state=42
   15 )
   17 model = OneVsRestClassifier(algorithm)
-> 18 model.fit(X_train, Y_train)
   19 print("Model trained successfully.")
   20 joblib.dump(model, f"genre_classifier_{approach}_{algorithm.__class__.__name__}.joblib")

le c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\base.py:1336, in _fit_context.<locals>.decorator.<locals>.wrapper(estimator, *args, **kwargs
 1329     estimator._validate_params()
 1331 with config_context(
 1332     skip_parameter_validation=(
 1333         prefer_skip_nested_validation or global_skip_validation
 1334     )
 1335 ):
 1336     return fit_method(estimator, *args, **kwargs)
.
 1201         class_weight, classes=classes_, y=y, sample_weight=sample_weight
 1202     )
 1203 else:

lueError: This solver needs samples of at least 2 classes in the data, but the data contains only one class: np.int64(0)
tput is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...
```

2.3.4 Vulnerabilidades identificadas no treino

Durante a fase de treino verificou-se, como já referido, a existência de várias labels sem descrições de treino associadas, isto implica que os modelos não aprenderam situações que poderiam dar origem a essas classes e por isso nunca vão ser capazes de as prever.

```
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 2 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 84 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 89 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 150 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 167 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 227 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 242 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 250 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 307 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 336 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 337 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 344 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 350 is present in all training examples.
...
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 817 is present in all training examples.
  warnings.warn(
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\sklearn\multiclass.py:90: UserWarning: Label not 839 is present in all training examples.
  warnings.warn(
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...
Model trained successfully.
```

Após alguma análise às classes existentes, verifica-se cerca de 25% das classes têm menos de 5 registos de descrições.

```
few_genres = df["genres"].apply(lambda x: str(x).split("|")).explode().value_counts()
few_genres = few_genres[few_genres < 5]

print(few_genres)
```
✓ 0.0s

```
genres
Hard Boiled             4
Cinderella              4
Fat                     4
Counter Culture         4
International Dev...    4
                       ..
Disability Studies      1
Peak Oil                1
Health Care             1
Read For College        1
Anthropomorphic         1
Name: count, Length: 237, dtype: int64
```

3.4 Teste e avaliação dos modelos

Foram realizados testes para os vários cenários e as métricas consideradas relevantes para estudo foram:

- **Accuracy**: A *accuracy* mede a proporção de previsões completamente corretas relativamente ao total de exemplos. No contexto multi-label, esta métrica é bastante exigente, uma vez que apenas considera uma previsão correta se todos os géneros associados a um livro forem corretamente identificados.
- **Hamming loss**: A *Hamming Loss* mede a fração de rótulos incorretamente previstos, considerando cada rótulo individualmente. Ao contrário da accuracy, esta métrica avalia cada decisão de forma independente, penalizando tanto a atribuição incorreta de um género (*falso positivo*) como a omissão de um género relevante (*falso negativo*). Por esta razão, a Hamming Loss é especialmente adequada para problemas multi-label, fornecendo uma medida direta do erro médio por rótulo.
- **Precision**: A *precision* avalia a qualidade das previsões positivas do modelo. Ou seja, mede a proporção de géneros previstos que estão realmente corretos. Um

valor elevado de precision indica que o modelo comete poucos falsos positivos, ou seja, evita atribuir géneros incorretos aos livros. Modelos com alta precision tendem a ser mais conservadores nas suas previsões.

- **Recall**: O *recall* mede a capacidade do modelo em identificar todos os géneros relevantes presentes nos dados. Em outras palavras, avalia quantos dos géneros reais foram corretamente previstos. Um valor elevado de recall indica que o modelo consegue capturar a maioria dos géneros associados a cada livro, embora possa incluir alguns erros. Modelos com alto recall tendem a ser mais permissivos.
- **F1 score**: O *F1-score* combina precision e recall numa única métrica, através da sua média harmónica. Esta métrica é particularmente útil quando se pretende um equilíbrio entre evitar falsos positivos e minimizar falsos negativos. Um F1-score elevado indica que o modelo apresenta um bom compromisso entre precisão e cobertura, sendo por isso uma das métricas mais relevantes para problemas de classificação multi-label.

Decidiu-se usar as métricas micro-averaged (para precision, recall e f1 score) porque sabe-se que há um desequilíbrio entre classes e pretendesse dar mais ênfase aos géneros mais frequentes, pois os menos frequentes são mais sujeitos a ruídos e podem prejudicar a avaliação dos modelos.

Como o âmbito do trabalho é deduzir os géneros a que pertence o livro e sendo uma solução multi-label com uma dimensão de mais de 800 labels, considerou-se desnecessário avaliar métricas sobre os negativos como a Especificidade (specifity) e o valor negativo preditivo (NPV).

```
from sklearn.metrics import hamming_loss, accuracy_score, f1_score, precision_score, recall_score
model = joblib.load("genre_classifier_1_LogisticRegression.joblib")
Y_probs = model.predict_proba(X_test)

thresholds = (0.5, 0.4, 0.3, 0.2, 0.1)
values = [["Hamming Loss"], ["Accuracy"], ["Precision (micro)"], ["Recall (micro)"], ["F1 Score (micro)"]]
for threshold in thresholds:
    genre_pred = (Y_probs >= threshold).astype(int)

    hloss = hamming_loss(Y_test, genre_pred)
    acc = accuracy_score(Y_test, genre_pred)
    precision_micro = precision_score(Y_test, genre_pred, average='micro')
    recall_micro = recall_score(Y_test, genre_pred, average='micro')
    f1_micro = f1_score(Y_test, genre_pred, average='micro')

    values[0].append(f"{hloss:.4f}")
    values[1].append(f"{acc:.4f}")
    values[2].append(f"{precision_micro:.4f}")
    values[3].append(f"{recall_micro:.4f}")
    values[4].append(f"{f1_micro:.4f}")

results_df = pd.DataFrame(values, columns=["Metric"] + [str(th) for th in thresholds])
print(results_df)
✓ 35.0s
```

A análise dos resultados foi realizada considerando diferentes *thresholds de probabilidade* (0.5 a 0.1), permitindo avaliar o comportamento dos modelos em diferentes níveis de exigência na atribuição de rótulos.

Métrica	Algoritmo	Probability thresholds				
		0.5	0.4	0.3	0.2	0.1
Hamming loss	TF-IDF + Logistic reg.	0.0047	0.0046	0.0047	0.0052	0.0078
	TF-IDF + XGBoost	0.0046	0.0046	0.0048	0.0055	0.0081
	SBERT + Logistic reg.	0.0047	0.0047	0.005	0.0058	0.0089
	SBERT + XGBoost	0.0046	0.0046	0.0047	0.005	0.006
Accuracy	TF-IDF + Logistic reg.	0.0326	0.0353	0.0354	0.0208	0.0022
	TF-IDF + XGBoost	0.0352	0.0383	0.0354	0.022	0.0013
	SBERT + Logistic reg.	0.0277	0.0279	0.0235	0.0109	0.0003
	SBERT + XGBoost	0.0359	0.0403	0.0382	0.0307	0.0114
Precision	TF-IDF + Logistic reg.	0.7985	0.7441	0.675	0.5776	0.4148
	TF-IDF + XGBoost	0.7681	0.7098	0.6417	0.5501	0.4022
	SBERT + Logistic reg.	0.7372	0.6718	0.5986	0.5053	0.3649
	SBERT + XGBoost	0.7646	0.7192	0.6643	0.5982	0.4963
Recall	TF-IDF + Logistic reg.	0.3151	0.3796	0.4546	0.5444	0.6697
	TF-IDF + XGBoost	0.3549	0.42	0.49	0.5663	0.675
	SBERT + Logistic reg.	0.3245	0.3924	0.4696	0.5589	0.6863
	SBERT + XGBoost	0.3219	0.3753	0.4297	0.4918	0.5803
F1 Score	TF-IDF + Logistic reg.	0.4519	0.5028	0.5433	0.5605	0.5123
	TF-IDF + XGBoost	0.4855	0.5277	0.5557	0.5581	0.504
	SBERT + Logistic reg.	0.4507	0.4955	0.5263	0.5307	0.4764
	SBERT + XGBoost	0.4531	0.4933	0.5219	0.5398	0.535

3.4.1. Impacto do Threshold

Observa-se um comportamento consistente em todos os modelos:

- A diminuição do threshold resulta num aumento do **recall**
- Em contrapartida, verifica-se uma diminuição da **precision**

Este comportamento evidencia o trade-off típico em problemas de classificação multi-label, onde thresholds mais baixos tornam o modelo mais permissivo, aumentando a cobertura de rótulos, mas também o número de falsos positivos.

3.4.2. Accuracy

Os valores de accuracy são relativamente baixos (~0.03–0.04), o que é esperado em problemas multi-label, dado que esta métrica exige a previsão correta de todos os rótulos de uma instância.

3.4.3. Hamming Loss

De forma geral os modelos apresentaram bons modelos de hamming loss, com valores consistentemente abaixo de 0.05 para thresholds mais elevados.

Este resultado indica que este modelo é o mais eficaz na previsão individual de rótulos, apresentando menor taxa de erro por label.

Mas este valor não é muito fiável, porque sabemos que o sistema foi treinado com mais de 800 labels e tipicamente por livro, não existe mais de 5 labels atribuídas, ou seja, todas as outras 800 são zeros, o que deduzimos que o modelo aprendeu bem a dizer que não é do género.

Verifica-se também que o Hamming Loss aumenta à medida que o threshold diminui que se justifica com o aumento do número de positivos, o que eleva a probabilidade de erro.

3.4.4 Accuracy, recall e F1 score

Uma precision elevada é boa, significa que muitos rótulos previstos estão corretos, mas isto pode dever-se ao facto de termos muitos rótulos e, geralmente, um livro ter apenas 2 ou 3 géneros, pelo que todos os outros 800 seriam 0. Ou seja, ele aprendeu bem a dizer quando não pertence ao género e tornou-se conservador.

Um recall baixo não é bom, isto significa que se perdem muitos géneros verdadeiros.

A alta precisão aliado ao baixo recall e baixo F1 indica que são modelos cautelosos, prevê poucas etiquetas, as que prevê estão geralmente correctas (alta precisão), mas deixa de identificar muitos géneros verdadeiros (baixo recall).

O ponto ideal encontra-se quando o threshold está a 0.2, em que os modelos são mais "ousados" e apesar de a precision diminuir, o recall aumenta mais expressivamente, o que se reflete no aumento do f1 score.

De uma forma geral o SGBoost é mais equilibrado e constante ao longo dos thresholds que a Regressão linear.

3.4.5 Comparação entre representações de texto

Contrariamente ao esperadoos modelos baseados em TF-IDF superaram os baseados em SBERT na maioria dos cenários.

Possíveis justificações:

- O problema depende fortemente de palavras-chave específicas associadas aos géneros
- O dataset pode não ser suficientemente grande para tirar total proveito de embeddings contextuais
- SBERT pode suavizar diferenças importantes entre géneros

3.5 Utilização dos modelos

Por fim, os modelos foram usados em textos livres de forma a validar manualmente a sua eficácia e a sua usabilidade em ambientes produtivos. Usou-se um threshold de 0.5.

```python
threshold = 0.5
approach = input("Choose approach (1 for TF-IDF, 2 for Sentence Transformers): ")
algorithm = input("Choose algorithm (1 for Logistic Regression, 2 for XGBoost): ")

algorithm_name = ""
if algorithm == "1":
    algorithm_name = "LogisticRegression"
elif algorithm == "2":
    algorithm_name = "XGBClassifier"

model = joblib.load(f"genre_classifier_{approach}_{algorithm_name}.joblib")
mlb = joblib.load(f"mlb_{approach}.joblib")
print("Model loaded successfully.")


def apply_preprocessing(texts):
    if approach == "1":
        return vectorizer.fit_transform([preprocess(clean_text(text)) for text in texts])
    elif approach == "2":
        return transformer.encode(
            [clean_text(text) for text in texts],
            normalize_embeddings=True,
            device=device
        )
    else:
        raise ValueError("Invalid approach selected. Please choose 1 or 2.")

texts = (
    "London, 1888. Beneath the fog-filled streets and flickering gas lamps, the city whispers
    "In a distant future where advanced technology has unlocked portals to forgotten realms, h
    "The Parker family just wanted a peaceful weekend getaway in the countryside. Instead, the
    "Lena never believed in fate. As a determined art student trying to balance college, part-
    "For as long as they can remember, five friends have shared one strange thing in common: a
    "Num reino onde a magia é proibida e as estrelas são vistas como presságios de desgraça, E
)
texts_vectors = apply_preprocessing(texts)

# Predict probabilities
genre_probs = model.predict_proba(texts_vectors)

for i, probs in enumerate(genre_probs):
    print(f"Book {i+1} genre probabilities:")
    for j, genre in enumerate(mlb.classes_):
        if probs[j] >= threshold:
            print(f"  {genre}: {probs[j]:.4f}")
```

✓ 9.7s

Texto	Géneros esperados	Géneros previstos	
		Regressão logistica	XGBoost
London, 1888. Beneath the fog-filled streets and flickering gas lamps, the city whispers with rumors of a series of strange disappearances. Each vanished person was last seen near the same narrow alley in Whitechapel—and each left behind an identical object: a small, intricately crafted pocket watch that always stops at exactly 3:17 a.m.	Historical Mystery	Fantasy: 0.5111 Fiction: 0.8768 Science Fiction: 0.5403	Fiction: 0.8196
In a distant future where advanced technology has unlocked portals to forgotten realms, humanity discovers a hidden universe filled with ancient magic and mythical creatures. When a young astrophysicist accidentally activates a long-dormant gateway orbiting Earth, she unleashes a mysterious force that begins merging science and sorcery.	Fantasy Science Fiction	Fantasy: 0.9778 Fiction: 0.7160 Science Fiction: 0.9398	Fantasy: 0.9738 Fiction: 0.7273 Science Fiction: 0.9425
When the extremely average Martinez family moves into a huge old mansion they got suspiciously cheap online, they think they've found the deal of a lifetime. The listing promised “historic charm, vintage architecture, and lively energy.” It did not mention the lively energy is an entire community of extremely annoying ghosts.	Horror Family	Fiction: 0.8052 Horror: 0.9225	Childrens: 0.5851 Fantasy: 0.567 Fiction: 0.7585 Horror: 0.9234 Mystery: 0.5486
Lena never believed in fate. As a determined art student trying to balance college, part-time jobs, and her dreams of becoming a painter, she’s convinced life is all about hard work—not destiny. Then she literally collides with Noah. Noah is a quiet but thoughtful engineering student who prefers books and late-night coffee over crowded parties. When Lena accidentally spills an entire cup of coffee over	Romance Young Adults	Romance: 0.7736	Romance: 0.6354

his carefully organized notes in a campus café, their first meeting is anything but romantic.			
For as long as they can remember, five friends have shared one strange thing in common: absolutely terrible luck.\nThere's Jake, who once slipped on a banana peel… in a parking lot… where there were no bananas.\nMaya, whose phone always dies exactly when something important happens.\nLuis, who somehow sets off alarms in stores even when he doesn't buy anything.\nSophie, whose GPS constantly sends the group to the wrong places.\nAnd Ben, who has broken six chairs in his life just by sitting down.\nDespite their ridiculous streak of misfortune, they decide to finally do something exciting together: a weekend road trip to attend a huge festival.	Comedia	Fiction: 0.6840 Mystery: 0.5175	Fiction: 0.7397 Mystery: 0.5738
Num reino onde a magia é proibida e as estrelas são vistas como presságios de desgraça, Elara esconde um segredo que pode mudar tudo: ela consegue ouvir o sussurro do céu.\nQuando conhece Kael, um misterioso viajante com um passado envolto em sombras, o destino de ambos entrelaça-se de forma inesperada. À medida que forças antigas despertam e uma guerra se aproxima, Elara e Kael são obrigados a confiar um no outro para sobreviver.	Romance Fantasy	Fantasy: 0.9975 Fiction: 0.6147 Magic: 0.6290 Young Adult: 0.6794	Fantasy: 0.9936 Fiction: 0.5865 Young Adult: 0.5692

4 Conclusões finais e trabalho futuro

- O uso de XGBoost melhora o desempenho face à Regressão Logística, sendo mais equilibrado (melhor F1 score e melhor hamming loss) ao longo dos thresholds;
- TF-IDF continua altamente competitivo, especialmente em tarefas baseadas em palavras-chave;
- O ajuste do threshold é crucial em problemas multi-label. E de forma a otimizar a solução, poderia-se explorar o threshold ótimo por label;
- Diferentes métricas levam a conclusões diferentes, sendo o F1-score a mais equilibrada;
- Existe um grande desequilíbrio de frequência entre géneros;
- Custo computacional elevado para embeddings contextuais.

5 Tecnologias Utilizadas

- Python
- Pandas / NumPy
- Scikit-learn (Regressão Logística, SVM, métricas, divisão de dados)
- XGBoost
- Sentence-BERT (multilingual)
- NLTK
- Jupyter Notebook
- FastText

6 Anexos

Repositório de git com trabalho realizado:

https://github.com/diogosantosmendes/executivemaster_pln_tp1

Documentos gerados durante a execução:

book_desc_embeddings.npy	3/16/2026 7:49 PM	NPY File	98,005 KB
genre_classifier_1_LogisticRegression.joblib	3/17/2026 10:18 PM	JOBLIB File	32,002 KB
genre_classifier_1_XGBClassifier.joblib	3/18/2026 2:22 AM	JOBLIB File	413,987 KB
genre_classifier_2_LogisticRegression.joblib	3/16/2026 8:16 PM	JOBLIB File	3,640 KB
genre_classifier_2_XGBClassifier.joblib	3/16/2026 9:31 PM	JOBLIB File	468,429 KB
mlb_1.joblib	3/18/2026 2:50 AM	JOBLIB File	12 KB
mlb_2.joblib	3/18/2026 2:51 AM	JOBLIB File	13 KB