IMPLEMENTAÇÃO DE UM CLASSIFICADOR COM TRANSFORMERS

Processamento de Linguagem Natural e LLM

Abstract

Design de um classificador de géneros de livros com base nas suas sinopses.

Diogo Mendes

20251612

Contents

1. Contexto do Estudo 3
2. Metodologia 3
2.1. Recolha de Dados 3
2.2. Pré-Processamento 4
2.2.1 Limpeza genérica dos dados 5
2.2.2 representação do texto 5
2.2.2.1 TF-IDF para inglês 7
2.2.2.2 SBERT multilingue 8
2.2.3 Representação das classes 9
2.2.3.1 Redução de classes com HDBSCAN 10
2.2.3.2 Redução de classes com Clustering hierárquico 11
2.2.3.3 Binarização das classes 12
2.3 Modelação e Treino 13
2.3.1 Regressão Logística 14
2.3.2 XGBoost 14
2.3.3 SVM 15
2.4 Teste e avaliação dos modelos 15
3.4.1. Impacto do Threshold 17
3.4.2. Accuracy 17
3.4.3. Hamming Loss 18
3.4.4 Accuracy, recall e F1 score 18
3.4.5 Comparação entre representações de texto 18
3.4.6 Avaliação de resultados para thresholds calculados por label 19
3.4.7 Comparação global da solução 19
3.5 Utilização dos modelos 19
4 Conclusões finais e trabalho futuro 21
5 Tecnologias Utilizadas 21
6 Anexos 23

6.1 Repositório de git com trabalho realizado: 23
6.2 Documentos gerados durante a execução: 23
6.3 Comparação de métricas para thresholds otimizados por género 24
6.4 Comparação geral de métricas 24
6.5 Testes de inferência com valores manuais 25
6.5.1 Textos para testes de inferência 27

1. Contexto do Estudo

A classificação automática de texto é uma tarefa fundamental no Processamento de Linguagem Natural (NLP), com aplicações em áreas como análise de sentimentos, categorização de documentos e sistemas de recomendação. Com o avanço recente dos modelos baseados em Transformers, como o BERT, tornou-se possível capturar relações semânticas complexas entre palavras e frases.

O objetivo deste trabalho consiste em desenvolver e avaliar diferentes abordagens para classificação de texto, comparando métodos tradicionais baseados em estatística com métodos baseados em embeddings derivados de modelos Transformers. Embora o problema clássico seja a análise de sentimentos, neste trabalho foi considerado um cenário mais geral de classificação multi-label, onde cada texto pode pertencer a múltiplas categorias.

2. Metodologia

O projeto foi desenvolvido seguindo as seguintes fases:

2.1. Recolha de Dados

Foi recolhido o dataset “Goodreads' Best Books Ever” disponível no Kaggle, que entre os vários campos, destacam-se a Descrição textual (book_desc) e os géneros (genres)

Fonte: https://www.kaggle.com/datasets/meetnaren/goodreads-best-books

book_authors	book_desc	book_edition	book_form	book_isbn	book_pages	book_rating	book_rat	book_revi	book_title	genres	imag
Suzanne Collins	Winning will make you famous. Losing mea		Hardcover	9.78044E+12	374 pages	4.33	5519135	160706	The Hunger Games	Young Adult|Fiction|Science Fiction|Dystopia|Fa	https
J.K. Rowling|Mary GrandPré	There is a door at the end of a silent corrido	US Edition	Paperback	9.78044E+12	870 pages	4.48	2041594	33264	Harry Potter and the Order of the Phoenix	Fantasy|Young Adult|Fiction	https
Harper Lee	The unforgettable novel of a childhood in a	50th Anniversary	Paperback	9.78006E+12	324 pages	4.27	3745197	79450	To Kill a Mockingbird	Classics|Fiction|Historical|Historical Fiction|Ac	https
Jane Austen|Anna Quindlen|Mrs. Oliv	«È cosa ormai risaputa che a uno scapolo i	Modern Library Classics, USA / CAN	Paperback	9.78068E+12	279 pages	4.25	2453620	54322	Pride and Prejudice	Classics|Fiction|Romance	https
Stephenie Meyer	About three things I was absolutely positive		Paperback	9.78032E+12	498 pages	3.58	4281268	97991	Twilight	Young Adult|Fantasy|Romance|Paranormal|Van	https
Markus Zusak	Trying to make sense of the horrors of Worl	First American Edition (US / CAN)	Hardcover	9.78038E+12	552 pages	4.36	1485632	100821	The Book Thief	Historical|Historical Fiction|Fiction|Young Adult	https
C.S. Lewis|Pauline Baynes	Journeys to the end of the world, fantastic c	Reissue Edition	Paperback	9.78007E+12	767 pages	4.25	437829	9439	The Chronicles of Narnia	Fantasy|Classics|Fiction|Young Adult|Childrens	https
George Orwell	مزرعة الحيوانات هي رائعة جورج أورويل الخالدة، الت		Paperback	9.78045E+12	122 pages	3.9	2235084	42156	Animal Farm	Classics|Fiction|Science Fiction|Dystopia|Fanta	https
Margaret Mitchell	Gone with the Wind is a novel written by Ma		Paperback	9.78045E+12	1037 pages	4.29	969181	17452	Gone with the Wind	Classics|Historical|Historical Fiction|Fiction|Rom	https
J.R.R. Tolkien	الجزء الثالث من ملحمة جيه آر آر تولكين الرائعة سيد الخ	Hobbit Movie Tie-in Boxed set	Mass Market	9.78035E+12	1728 pages	4.59	99793	1652	J.R.R. Tolkien 4-Book Boxed Set: The Hobb	Fantasy|Fiction|Classics	https
John Green	Despite the tumor-shrinking medical miracl		Hardcover	9.78053E+12	313 pages	4.24	2881648	147270	The Fault in Our Stars	Young Adult|Fiction|Romance|Contemporary	https
Douglas Adams	Seconds before the Earth is demolished to m		Paperback	9.78035E+12	193 pages	4.21	1155911	23919	The Hitchhiker's Guide to the Galaxy	Science Fiction|Fiction|Humor|Fantasy|Classics	https
Shel Silverstein	"Once there was a tree...and she loved a litt		Hardcover	9.78006E+12	64 pages	4.37	789681	15694	The Giving Tree	Childrens|Childrens|Picture Books|Classics|Fict	https
Emily Brontë|Richard J. Dunn|David T	You can find the redesigned cover of this ed	Fourth Edition	Paperback	9.78039E+12	464 pages	3.84	1121100	29400	Wuthering Heights	Classics|Fiction|Romance|Literature	https
Dan Brown	An ingenious code hidden in the works of Le		Paperback	9.78031E+12	481 pages	3.81	1668594	43699	The Da Vinci Code	Fiction|Mystery|Thriller	https
Arthur Golden	A literary sensation and runaway bestseller	Large Print	Hardcover	9.78074E+12	434 pages	4.09	1525851	27168	Memoirs of a Geisha	Fiction|Historical|Historical Fiction|Romance|Hi	https
Lewis Carroll|John Tenniel|Martin Gar	" I can't explain myself, I'm afraid, sir," said		Mass Market	9.78045E+12	239 pages	4.07	411153	9166	Alice's Adventures in Wonderland & Thro	Classics|Fantasy|Fiction|Childrens	https
Oscar Wilde|Jeffrey Eugenides	Written in his distinctively dazzling manner,	Modern Library Classics	Paperback	9.78038E+12	367 pages	4.06	775701	22938	The Picture of Dorian Gray	Fiction|Classics|Horror|Fantasy|Literature|Goth	https
Victor Hugo|Lee Fahnestock|Norman	Introducing one of the most famous charac		Mass Market	9.78045E+12	1463 pages	4.15	591874	13063	Les Misérables	Classics|Fiction|Historical|Historical Fiction|Lit	https
Veronica Roth	In Beatrice Prior's dystopian Chicago world,		Paperback	9.78006E+12	487 pages	4.22	2493519	104329	Divergent	Young Adult|Science Fiction|Dystopia|Fiction|Fa	https
Charlotte Brontë|Michael Mason	Fiery love, shocking twists of fate, and tragic	Penguin Classics	Paperback	9.78014E+12	507 pages	4.11	1381404	34670	Jane Eyre	Classics|Fiction|Romance|Historical|Historical	https
William Shakespeare|Barbara A. Mow	In Romeo and Juliet, Shakespeare creates a	New Folger edition	Mass Market	9.78074E+12	283 pages	3.74	1818262	16442	Romeo and Juliet	Classics|Plays|Fiction|Romance|Academic|Sch	https
William Golding	At the dawn of the next world war, a plane c	Penguin Great Books of the 20th Centur	Paperback	9.78014E+12	182 pages	3.66	1840595	30634	Lord of the Flies	Classics|Fiction|Young Adult|Academic|School|	https
Paulo Coelho|Alan R. Clarke|Özdemir	Paulo Coelho's masterpiece tells the mystic		Paperback	9.78006E+12	197 pages	3.84	1644387	63861	The Alchemist	Fiction|Classics|Fantasy|Philosophy|Novels|Spi	https
Fyodor Dostoyevsky|David McDuff	Raskolnikov, an impoverished student livin	Penguin Classics	Paperback	9.78014E+12	671 pages	4.2	507522	14496	Crime and Punishment	Classics|Fiction|Cultural|Russia|Literature|Liter	https
Orson Scott Card	Andrew "Ender" Wiggin thinks he is playing	Author's Definitive Edition, Revised mas	Mass Market	9.78081E+12	324 pages	4.3	965351	40289	Ender's Game	Science Fiction|Fiction|Young Adult|Fantasy	https
Stephen Chbosky	The critically acclaimed debut novel from St		Paperback	9.78067E+12	213 pages	4.2	1063711	50846	The Perks of Being a Wallflower	Young Adult|Fiction|Contemporary	https
Cassandra Clare|Franca Fritz|Heinric	When fifteen-year-old Clary Fray heads out t		Hardcover	9.78142E+12	485 pages	4.11	1383479	55446	City of Bones	Fantasy|Young Adult|Fantasy|Paranormal|Roma	https
Kathryn Stockett	Be prepared to meet three unforgettable wo		Hardcover	9.7804E+12	465 pages	4.46	1790905	80741	The Help	Fiction|Historical|Historical Fiction|Historical|Ar	https
F. Scott Fitzgerald	Alternate Cover Edition ISBN: 0743273567 (IS	US / CAN	Paperback		180 pages	3.9	3141842	56953	The Great Gatsby	Classics|Fiction|Academic|School|Literature|Hi	https
Audrey Niffenegger	A funny, often poignant tale of boy meets gir	Special Edition	ebook		500 pages	3.96	1408080	45153	The Time Traveler's Wife	Fiction|Romance|Fantasy|Science Fiction|Time T	https
E.B. White|Garth Williams|Rosemary	This beloved book by E. B. White, author of	Full Color Edition	Paperback	9.78006E+12	184 pages	4.16	1199733	14938	Charlotte's Web	Classics|Childrens|Fiction	https
L.M. Montgomery	As soon as Anne Shirley arrives at the snug		Paperback	9.78045E+12	320 pages	4.24	599365	16797	Anne of Green Gables	Classics|Fiction|Young Adult|Childrens|Historic	https
John Steinbeck	The compelling story of two outsiders strivi	Steinbeck Centennial Edition, US / CAN	Paperback	9.78014E+12	112 pages	3.85	1662561	27999	Of Mice and Men	Classics|Fiction|Academic|School|Literature|Hi	https
Bram Stoker|Nina Auerbach|David J.	You can find an alternative cover edition for Norton Critical Edition		Paperback	9.78039E+12	488 pages	3.98	775448	19726	Dracula	Classics|Horror|Fiction|Fantasy|Paranormal|Va	https

2.2. Pré-Processamento

Os dados foram carregados e representados em estruturas tabulares disponibilizadas pela biblioteca “pandas”.

```
import pandas as pd
df = pd.read_csv("tp1_dataset.csv", usecols=["book_desc", "genres"])

print(df.shape)
print(df.dtypes)
```

✓ 3.6s

```
(54301, 2)
book_desc    str
genres       str
dtype: object
```

Após uma breve análise às descrições, foi possível concluir:

- O número de descrições (52970) não corresponde ao número de linhas do dataset (54301), ou seja, existem livros sem descrição, o que devem ser retirados;
- O numero de descrições únicas (51781) não corresponde ao total de descrições (52970), o que podemos concluir que existem descrições duplicadas;
- Descrições em múltiplas líguas e até em outros sistemas de escrita além do Alfabético, como por exemplo em Abjad (Árabe);
- Algumas descrições continham caracteres de indentação ou a própria representação desses caracteres em texto, como o carriage return (\r) e o line feeding (\n), o que não acrescenta valor semântico ao texto e pode prejudicar o processo de tokenização, gerando embeddings ligeiramente diferentes para a mesma sentença.

```
print(df["book_desc"].head(10))
print(df["book_desc"].describe())
```

✓ 0.0s

```
0    Winning will make you famous. Losing means cer...
1    There is a door at the end of a silent corrido...
2    The unforgettable novel of a childhood in a sl...
3    «È cosa ormai risaputa che a uno scapolo in po...
4    About three things I was absolutely positive.F...
5    Trying to make sense of the horrors of World W...
6    Journeys to the end of the world, fantastic cr...
7    مزرعة الحيوانات هي رائعة جورج أورويل الخالدة.....
8    Gone with the Wind is a novel written by Marga...
9    ... لجزء الثالث من ملحمة جيه أر أر تولكين الرائعة
Name: book_desc, dtype: str
count                                            52970
unique                                           51781
top       ...هذه هي طبعة "دار الفكر - بيروت" وهي آخر طبعة ع
freq                                                38
Name: book_desc, dtype: object
```

```
repeated = df.groupby(["book_desc"]).size().reset_index(name="count")
repeated = repeated[repeated["count"] > 1]

print(repeated)
```

✓ 0.0s

```
                                          book_desc  count
238    \r\n\r\n\r\nBased on the true story of a forgo...      2
557    \r\n\r\nWar has erupted in the Banished Lands ...      2
926     Until now, he's existed only in her dreams -b...      2
956     milk and honey  is a collection of poetry and...      2
1135   "As Gregor Samsa awoke one morning from uneasy...      2
...                                                  ...    ...
51258  “Did you ever hear the Tragedy of Darth Plague...      2
51304  “Her knees were weak and if not for that marbl...      2
51461  “Our Dragon doesn’t eat the girls he takes, no...      2
51640  „Als ich zum ersten Mal in deine Augen sah, wu...      2
51649  „Dievų miškas“ — memuarinis lietuvių rašytojo ...      2

[926 rows x 2 columns]
```

2.2.1 Limpeza genérica dos dados

Para resolver as inconsistências apresentadas foi então realizado um processo de limpeza dos dados, removendo os duplicados e nulos, removendo caracteres sem valor semântico e normalizando os textos para Unicode, facilitando a interpretação dos textos, especialmente em sistemas de escrita distintos.

```python
def clean_text(text):
    # if the text is NaN (missing value), return it as is to avoid processing
    if pd.isna(text):
        return text
    text = str(text)
    # remove carriage returns and line feeds
    text = re.sub(r"(\\[rn]|[\r\n])+", " ", text)
    # replace multiple whitespace characters with a single space and trim leading/trailing whitespace
    text = re.sub(r"\s+", " ", text).strip()
    # if the resulting text is empty after cleaning, return None to indicate missing value
    if text == "":
        return None
    # normalize to unicode to ensure consistent representation of characters
    text = unicodedata.normalize("NFKC", text)
    return text

def clean_dataset(df):
    df["book_desc_clean"] = df["book_desc"].apply(clean_text)
    # drop null values from descriptions and genres, as they cannot be used for training the model
    df = df.dropna(subset=["book_desc_clean", "genres"])
    # drop duplicated descriptions
    df = df.drop_duplicates(subset="book_desc_clean", keep="last")
    # reset index after dropping rows to avoid issues with indexing later on
    df = df.reset_index(drop=True)
    return df
```

2.2.2 representação do texto

Após a observação das múltiplas linguagens, verificou-se que não existia uma coluna no dataset que identifique a linguagem, por isso foi feito um estudo sobre as linguagens das descrições e a contagem de descrições por linguagem com elevado grau de confiança (superior a 70%).

Para este estudo foi usado a biblioteca “fast-textdetect” (https://github.com/LlmKira/fast-langdetect) baseado no “fasttext” desenvolvido pelo Facebook que usa um modelo pré-treinado capaz de identificar 157 linguagens (https://github.com/facebookresearch/fastText)

```python
from fast_langdetect import detect

lang_confidence_threshold = 0.7

def detect_language(text):
    result = detect(str(text), model='lite', k=1)
    return result[0]["lang"], result[0]["score"]

df[["lang", "lang_confidence"]] = df["book_desc_clean"].apply(lambda x: pd.Series(detect_language(x)))
df["high_conf"] = df["lang_confidence"] > lang_confidence_threshold

languages_stats = df.groupby("lang").agg(
    high_confidence=("high_conf", "sum"),
    total=("lang", "size")
)
print(languages_stats.to_string())
```

✓ 3.9s

```
c:\Users\z004n7mh\AppData\Local\Programs\Python\Python314\Lib\site-packages\tqdm\auto.py:21: TqdmWarning: IProgr
  from .autonotebook import tqdm as notebook_tqdm
      high_confidence  total
lang
af                0      1
ar              680    695
arz               1      2
azb               0      1
bg               71     77
bn               26     26
bs                0      1
ca                8     12
ceb               0      3
cs              105    108
da               41     68
de              574    641
el               94     95
en            39383  42674
eo                0      2
es              828    891
et               16     21
fa              126    135
fi               90     94
fr              555    594
fy                0      1
gl                1      3
hi                5      6
```

Com esta análise conclui-se que existem poucas descrições para cada linguagem à exceção de inglês, com 39383 descrições com elevada confiança de assertividade.

A existência de textos em diversas línguas levantou o problema da metodologia a aplicar par a a representação dos textos, pois os processos básicos de NLP são tipicamente monolingue, e tendo um dataset com tamanha diversidade restam apenas duas soluções:

1) Utilizar o vectorização por TF-IDF, que requer algumas estratégias adicionais de NLP para reduzir o ruído nos dados, mantendo o contexto, como a remoção de stopwords e a lematização. No entanto, esta abordagem só é viável para os livros que temos quase a certeza que estão em inglês.
2) Utilizar um modelo de embeddings multilingue pré-treinado (como o Sentence-BERT) para gerar um vetor de tamanho fixo que suporte vários idiomas e preserve a semântica. Como é quase agnóstico em relação à língua, podemos utilizar todas as descrições, 51754 registos.

Foi então decidido implementar as duas abordagens para posteriormente comparar resultados.

2.2.2.1 TF-IDF para inglês

O método TF-IDF permite a captura da relevância relativa das palavras no texto, mas para isso foi necessário processamento adicional para evitar o ruído nos dados.

Seguindo então os seguintes passos:

- remoção de pontuação
- remoção de stopwords de inglês
- lematização das palavras

Foi evitado o uso de stemming porque este tem impacto computacional no treino do modelo similar à lematização mas por vezes pode gerar confusões semânticas.

Estes passos foram realizados com recurso às funções disponibilizadas na biblioteca “nltk”.

Por fim foram então convertidos os “lemas” em vectores usando a técnica TF-IDF

```python
vectorizer_file = "./generated/book_desc_vectorizer_tfidf.joblib"

def lemmatize_text(text):
    tokens = word_tokenize(text.lower())
    tokens = [
        lemmatizer.lemmatize(word)
        for word in tokens
        if word.isalpha() and word not in stop_words
    ]
    return " ".join(tokens)

def vectorize_descriptions_with_tfidf(descriptions):
    print("Lemmatizing descriptions...")
    lemmas = []
    for desc in descriptions:
        lemmas.append(lemmatize_text(str(desc)))

    if Path(vectorizer_file).exists():
        print("Loading precomputed vectorizer from file...")
        vectorizer = joblib.load(vectorizer_file)
    else:
        vectorizer = TfidfVectorizer(max_features=5000)

    if(not hasattr(vectorizer, "vocabulary_")):
        print("Fitting vectorizer to descriptions...")
        vectorizer.fit(lemmas)
        joblib.dump(vectorizer, vectorizer_file)

    X = vectorizer.transform(lemmas).toarray()

    return X
```

2.2.2.2 SBERT multilingue

Para a abordagem de vectorização das descrições usando Sentence-BERT (SBERT) foi usado um modelo multilingue que permite manter a semântica do texto de forma (quase)independente da linguagem. O modelo é também caracterizado por ser “Distil”, que exige menos capacidade computacional quando comparado aos semelhantes não “Distil”, com a desvantagem da (teórica) menor eficácia, por gerar vetores de menor dimensão, ou seja, menos embeddings.

Os textos não sofreram mais nenhuma alteração além da descrita no capítulo 2.2.1 Limpeza genérica dos dados para não haver qualquer perda semântica e porque o próprio modelo já tem imbutido a resolução de sub-words (evitando a necessidade de lematização).

A biblioteca utilizada foi a “sentence-tranformer” e foi também utilizado a placa gráfica (com arquitectura CUDA) para acelerar o encoding.

Por fim a matriz foi guardada num documento para facilitar trabalho futuro sobre os mesmos dados, evitando correr novamente este processamento.

```
embeddings_file = "./generated/book_desc_embeddings_sbert.npy"

def vectorize_descriptions_with_sbert(descriptions, use_file=True):
    if use_file and Path(embeddings_file).exists():
        print("Loading precomputed embeddings from file...")
        return np.load(embeddings_file)

    transformer = SentenceTransformer('distiluse-base-multilingual-cased-v2')
    X = transformer.encode(
        list(descriptions),
        batch_size=64,
        show_progress_bar=True,
        normalize_embeddings=True,
        device=device
    )

    if use_file:
        np.save(embeddings_file, X)

    return X
```

2.2.3 Representação das classes

Sendo que cada livro tinha um ou vários géneros associados, torna um problema de multi-label, o que implica um processamento adicional, isto é, não queremos apenas prever uma classe, queremos calcular a probabilidade de cada discrição pertencer a cada um dos géneros.

Após alguma análise às classes existentes, verifica-se cerca de 25% das classes têm menos de 5 registos de descrições.

```
few_genres = df["genres"].apply(lambda x: str(x).split("|")).explode().value_counts()
few_genres = few_genres[few_genres < 5]

print(few_genres)
✓ 0.0s

genres
Hard Boiled             4
Cinderella              4
Fat                     4
Counter Culture         4
International Dev...    4
                       ..
Disability Studies      1
Peak Oil                1
Health Care             1
Read For College        1
Anthropomorphic         1
Name: count, Length: 237, dtype: int64
```

Desta forma decidiu-se reduzir o número de labels. De forma a não perder volume de dados e usar todos os registos do dataset, procurou-se uam estratégia de agrupamento de labels por valor semântico. Para isso começou-se por transformar cada label num vator preservando o seu valor semântico utilizando novamente o SBERT com o modelo “all-MiniLM-L6-v2”.

Depois reduziu-se a dimensão dos embeddings, utilizando UMAP (Uniform Manifold Approximation and Projection) com o objetivo de a complexidade computacional.

```
def create_label_embeddings(genres_list):
    # extract unique genres
    all_genres = list(set([genre for book_genres in genres_list for genre in book_genres]))

    global device

    model = SentenceTransformer('all-MiniLM-L6-v2')  # lightweight and fast
    embeddings = model.encode(
        all_genres,
        batch_size=64,
        show_progress_bar=True,
        normalize_embeddings=True,
        device=device
    )

    # https://www.datacamp.com/pt/tutorial/understanding-umap-guide-to-dimensionality-reduction
    umap_embeddings = umap.UMAP(n_neighbors=20, min_dist=0.0, metric='cosine').fit_transform(embeddings)

    return all_genres, umap_embeddings
```

Foi verificado posteriormente, que a utilização de UMAP otimizou, adicionalmente, a o valor semântico dos géneros, pois evidenciou as características que os aproximam.

2.2.3.1 Redução de classes com HDBSCAN

HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise) é um algoritmo não supervisionado de clustering baseado em densidade. Não requer um número fixo de clusters e identifica outliers, no nosso caso géneros que dificilmente se associam as outros.

Ao executar este algoritmo identificou-se que para encontrar grupos com pelo menos 10 géneros, mais de metade dos géneros ficavam isolados (outliers), e então voltou-se a percorrer o método com um valor mínimo de elementos por cluster mais reduzido (2) de forma a refinar os agrupamentos.

```python
def cluster_labels_with_hdbscan(embeddings, all_genres):

    cluster_labels = hdbscan.HDBSCAN(min_cluster_size=10, metric='euclidean').fit_predict(embeddings)

    # Map each genre to its HDBSCAN cluster
    genre_to_label = {genre: label for genre, label in zip(all_genres, cluster_labels)}

    # Apply again HDBScan on the outliers with lower cluster size to refine sparser groups, avoiding too much genres under "Other" group
    outlier_idx = np.where(cluster_labels == -1)[0]
    outlier_genres = [all_genres[i] for i in outlier_idx]

    if len(outlier_genres) > 0:
        sub_clusterer = hdbscan.HDBSCAN(
            min_cluster_size=2,  # smaller to capture niche clusters
            metric='euclidean'
        )

        # get UMAP embeddings for outlier genres
        outlier_embeddings = embeddings[outlier_idx]
        # HDBSCAN on outliers
        sub_labels = sub_clusterer.fit_predict(outlier_embeddings)

        # Offset sub-cluster labels so they don't overlap with first pass
        max_label = cluster_labels.max()
        sub_labels = [s + max_label + 1 if s != -1 else -1 for s in sub_labels]

        # Update main genre_to_hdbscan mapping
        for genre, sub_label in zip(outlier_genres, sub_labels):
            genre_to_label[genre] = sub_label

    return genre_to_label
```

Classes agrupadas com HDBSCAN:

```
Total Clusters: 61

Cluster 14 "Fiction":
 occurrences: 52755
 genres: Adult Fiction, American Fiction, Amish Fiction, Animal Fiction, Anthologies, Autobiography, Biography, Biography Memoir, Bizarro Fiction, Diary, Essays, Fan Fiction, Fiction, Gay Fiction, Graphic Non Fiction, Historical Ficti

Cluster 16 "Fantasy":
 occurrences: 21515
 genres: Angels, Christian Fantasy, Cinderella, Cthulhu Mythos, Dark, Dark Fantasy, Demons, Epic, Epic Fantasy, Fables, Fae, Fairies, Fairy Tale Retellings, Fairy Tales, Fantasy, Folk Tales, Folklore, Forgotten Realms, Golden Age Myst

Cluster 09 "Romance":
 occurrences: 19876
 genres: African American Romance, Bdsm, Category Romance, Chick Lit, Christian Romance, Clean Romance, Contemporary Romance, Erotic Romance, Fantasy Romance, Futuristic Romance, Gay Romance, Historical Romance, Interracial Romance, L

Cluster 13 "Mystery":
 occurrences: 14821
 genres: Buffy The Vampire Slayer, Cozy Mystery, Detective, Gothic Horror, Horror, Legal Thriller, Mystery, Mystery Thriller, Paranormal Romance, Psychological Thriller, Suspense, Thriller, Werewolves

Cluster 48 "Young Adult":
 occurrences: 13318
 genres: Adolescence, Adult, Coming Of Age, Juvenile, New Adult, New Age, Teen, Young Adult, Young Adult Contemporary, Young Readers

Cluster 07 "Literature":
 occurrences: 11272
 genres: African American Literature, African Literature, Albanian Literature, Asian Literature, British Literature, Bulgarian Literature, Canadian Literature, Chinese Literature, Classic Literature, Criticism, Czech Literature, Dutch
...
Cluster 32 "Pornography":
 occurrences: 5
 genres: Pornography, Prostitution, Strippers
```

Grupo que inclui “Bsdm”

```
Check Cluster 9 "Romance":
  African American Romance
  Bdsm
  Category Romance
  Chick Lit
  Christian Romance
  Clean Romance
  Contemporary Romance
  Erotic Romance
  Fantasy Romance
  Futuristic Romance
  Gay Romance
  Historical Romance
  Interracial Romance
  Lesbian Romance
  Love Inspired Historical
  Love Inspired Suspense
  Love Story
  M F M
  M M F
  M M Fantasy
  M M Historical Romance
  M M M
  M M Romance
...
  Western Historical Romance
  Western Romance
  Westerns
  Young Adult Romance
```

Grupo que inclui “Erotica”

```
Check Cluster 8 "Erotica":
  Asexual
  Bisexual
  Boys Love
  Divorce
  Erotica
  Far Right
  Female Authors
  Feminism
  Gay
  Gay For You
  Gender
  Gender Studies
  Gender and Sexuality
  Genderqueer
  Harem
  Lesbian
  Lgbt
  Mail Order Brides
  Marriage
  Menage
  Nsfw
  Polyamorous
  Polyamory
...
  Sexuality
  Transgender
  Womens
  Womens Studies
```

2.2.3.2 Redução de classes com Clustering hierárquico

Clustering Hierárquico é outro algoritmo não supervisionado mas baseado em ligações (linkage). Este agrupa todos os valores, não existindo outliers. Neste algoritmo é definido o número de clusters que se pretende, foi definido o valor de 50 clusters.

```python
def cluster_labels_with_hierarchical_clustering(embeddings, all_genres, print_dendrogram=False):
    # Compute hierarchical linkage
    Z = linkage(embeddings, method='ward')  # 'ward' minimizes variance within clusters

    if print_dendrogram:
        # Plot dendrogram, useful for exploring structure
        plt.figure(figsize=(15, 5))
        dendrogram(Z, labels=all_genres, leaf_rotation=90, leaf_font_size=8)
        plt.show()

    # Cut tree to get clusters at desired level
    cluster_labels = fcluster(Z, 50, criterion='maxclust')

    # Map genres to clusters
    genre_to_label = {genre: label for genre, label in zip(all_genres, cluster_labels)}
    return genre_to_label
```

Classes agrupadas com Clustering Hierárquico:

```
Total Clusters: 50

Cluster 10 "Fiction":
 occurrences: 43089
 genres: Adult Fiction, American Fiction, Amish Fiction, Animal Fiction, Beauty and The Beast, Bizarro Fiction, Fan Fiction, Female Authors, Fiction, Flash Fiction, Gay Fiction, Graphic Non Fiction, Graphic Novels, Hard Science Fictio

Cluster 12 "Nonfiction":
 occurrences: 19055
 genres: Anthologies, Autobiography, Biography, Biography Memoir, Diary, Essays, Journal, Journaling, Journalism, Memoir, Nonfiction, Novella, Novels, Short Stories, Short Story Collection, Writing

Cluster 28 "Young Adult":
 occurrences: 18942
 genres: Abuse, Adolescence, Adoption, Adult, Childrens, Coming Of Age, Family, Family Law, Fostering, Human Development, Juvenile, Kids, Labor, Law, Mine, New Adult, New Age, Own, Parenting, Personal Development, Self Help, Teen, You

Cluster 25 "Fantasy":
 occurrences: 17971
 genres: Arthurian, Dark Fantasy, Dragonlance, Epic Fantasy, Fantasy, Forgotten Realms, Heroic Fantasy, High Fantasy, Historical Fantasy, Low Fantasy, Magical Realism, Mills and Boon, Sci Fi Fantasy, Science Fiction Fantasy, Storytime

Cluster 19 "Romance":
 occurrences: 16404
 genres: African American Romance, Category Romance, Christian Romance, Clean Romance, Contemporary Romance, Erotic Romance, Fantasy Romance, Futuristic Romance, Gay Romance, Historical Romance, Interracial Romance, Lesbian Romance, M

Cluster 23 "Mystery":
 occurrences: 13144
 genres: Detective, Halloween, Horror, Legal Thriller, Murder Mystery, Mystery, Mystery Thriller, Psychological Thriller, Spy Thriller, Suspense, Thriller, Zombies
...
Cluster 35 "Gardening":
 occurrences: 40
 genres: Agriculture, Alchemy, Gardening, Herbs, Horticulture, Plantagenet, Plants
```

Grupo que inclui “Erotica”

```
Check Cluster 15 "Erotica":
  Asexual
  Bisexual
  Erotic Horror
  Erotica
  Far Right
  Feminism
  Gay
  Gay For You
  Gender
  Gender Studies
  Gender and Sexuality
  Genderqueer
  Lesbian
  Lgbt
  Menage
  New Weird
  Nsfw
  Pornography
  Prostitution
  Queer
  Queer Lit
  Queer Studies
  Sex Work
...
  Strippers
  Transgender
  Womens
  Womens Studies
```

Grupo que inclui “Bsdm”

```
Check Cluster 17 "M M Romance":
  Bdsm
  M F M
  M M F
  M M Fantasy
  M M Historical Romance
  M M M
  M M Paranormal
  M M Romance
  M M Science Fiction
  Weird West
  Westerns
```

2.2.3.3 Binarização das classes

Por fim, foram atribuídos os grupos aos géneros no dataset, removidos os duplicados e foi então utilizado o *MultiLabelBinarizer* do “scikit-learn” para a conversão das diversas classes agrupadas para uma lista de valores binários, em que cada entrada corresponde a uma classe e tem o valor de 0 ou 1, mediante se tem aquele género ou não.

```python
def binarize_genres(genres_list, clustering_method, filename_suffix):
    genre_to_label_filename = f"./generated/genre_to_label_{filename_suffix}.joblib"

    if filename_suffix and Path(genre_to_label_filename).exists():
        print(f"Using {genre_to_label_filename}...")
        genre_to_label = joblib.load(genre_to_label_filename)
    else:
        all_genres, embeddings = create_label_embeddings(genres_list)
        genre_to_label = clustering_method(embeddings, all_genres)
        joblib.dump(genre_to_label, genre_to_label_filename)

    clusters_names = get_cluster_names(genres_list, genre_to_label)
    labelled_genres = genres_list.apply(lambda book_genres: list(set([clusters_names[genre_to_label[genre]] for genre in book_genres if genre in genre_to_label])))

    mlb_filename = f"./generated/mlb_{filename_suffix}.joblib"
    if filename_suffix and Path(mlb_filename).exists():
        print(f"Using {mlb_filename}...")
        mlb = joblib.load(mlb_filename)
    else:
        mlb = MultiLabelBinarizer()
        mlb.fit(labelled_genres)
        joblib.dump(mlb, mlb_filename)

    Y = mlb.transform(labelled_genres)

    return Y, mlb
```

2.3 Modelação e Treino

No presente trabalho, a classificação multi-label foi implementada utilizando a estratégia One-vs-Rest (OvR) através do *OneVsRestClassifier* da biblioteca “scikit-learn”.

A abordagem *One-vs-Rest* transforma um problema multi-label em vários problemas de classificação binária independentes:

- Para cada género é treinado um classificador binário:
    - Classe positiva (1): o texto pertence ao género
    - Classe negativa (0): o texto não pertence ao género

Assim são treinados tantos classificadores independentes quanto o número de géneros identificados no capítulo 2.2.3 Representação das classes.

Para efeitos de treino e teste os dados foram divididos em 2 partes (80% treino, 20% teste) de forma aleatória.

Após o término de fase de treino de cada modelo, este era gravado num ficheiro de forma a poder utilizar futuramente.

```python
def train_with(algorithm, X, Y, filename_suffix):
    # Split the dataset into training and testing sets (80% train, 20% test)
    X_train, X_test, Y_train, Y_test = train_test_split(
        X, Y, test_size=0.2, random_state=42
    )

    filename = f"./generated/genre_classifier_{filename_suffix}.joblib"
    # If a filename is provided and the file exists, load the model from the file. Otherwise, train a new model and save it to the file.
    if filename_suffix and Path(filename).exists():
        print(f"Using {filename}...")
        model = joblib.load(filename)
        return model, X_test, Y_test

    # Initialize the OneVsRestClassifier with the specified algorithm
    model = OneVsRestClassifier(algorithm)
    # Train the model on the training data
    model.fit(X_train, Y_train)
    # Save the trained model to a file for future use
    joblib.dump(model, filename)

    return model, X_test, Y_test
```

Para efeitos de aprendizagem e comparação de resultados foram utilizados dois algoritmos distintos:

- Regressão Logística
- XGBoost
- SVM

2.3.1 Regressão Logística

A Regressão Logística é um algoritmo de classificação supervisionada que estima a probabilidade de uma instância pertencer a uma classe específica com base nas suas características usando uma função sigmoide.

Tem as vantagens de ser fácil de implementar e interpretar, rápido para treinar em datasets grandes, funciona bem com dados esparsos, como TF-IDF, sendo a sua principal limitação a não captura de relações complexas entre características.

```
model, X_test, Y_test = train_with(LogisticRegression(max_iter=2000), X, Y)
```

2.3.2 XGBoost

O XGBoost (eXtreme Gradient Boosting) é um algoritmo de ensemble baseado em árvores de decisão, que constrói iterativamente um modelo forte a partir de vários modelos fracos (decision trees).

As suas árvores são construídas sequencialmente, onde cada nova árvore corrige os erros da anterior, que difere do Random Forests com a construção independente das árvores em paralelo.

O seu comportamento estocástico introduz subamostragem dos dados e redução de overfitting.

Este algoritmo, sendo um classificador não-linear, é capaz de encontrar padrões de co-ocorrencia, por exemplo Ficção científica acontecer diversas vezes junto com Fantasia.

Teoricamente tem melhor performance em muitos problemas complexos e funciona muito bem com embeddings. No entanto é mais lento. (no caso do presente trabalho foi 7x mais lento a ser gerado em comparação com a Regressão logística, usando a representação TF-IDF dos textos e o ficheiro gerado do modelo foi 13x superior).

```
model, X_test, Y_test = train_with(
    XGBClassifier(
        n_estimators=500,
        max_depth=6,
        learning_rate=0.05,
        subsample=0.8,
        device=device
    ), X, Y
)
```

2.3.3 SVM

O SVM (State vector machine) é um algoritmo geométrico que procura encontrar um hiperplano ótimo que separa as classes maximizando a margem entre elas.

Em teoria apresenta boa precisão quando comparado com os outros algoritmos não-NN com dados de elevada dimensionalidade, como no caso dos textos vetorizados, através do uso de Kernels.

Foi usado também o *CalibratedClassifierCV* da biblioteca "scikit-learn" para aplicar a calibração necessária para conseguir comparar as probabilidades das classes com os restantes algoritmos, pois, o SVM é representado geometricamente com um valor real da distância ao decision boundary, e não por um valor probabilístico.

```
model, X_test, Y_test = train_with(CalibratedClassifierCV(LinearSVC()), X, Y)
```

2.4 Teste e avaliação dos modelos

Foram realizados testes para os vários cenários e as métricas consideradas relevantes para estudo foram:

- **Accuracy**: A *accuracy* mede a proporção de previsões completamente corretas relativamente ao total de exemplos. No contexto multi-label, esta métrica é bastante exigente, uma vez que apenas considera uma previsão correta se todos os géneros associados a um livro forem corretamente identificados.
- **Hamming loss**: A *Hamming Loss* mede a fração de rótulos incorretamente previstos, considerando cada rótulo individualmente. Ao contrário da accuracy, esta métrica avalia cada decisão de forma independente, penalizando tanto a atribuição incorreta de um género (*falso positivo*) como a omissão de um género relevante (*falso negativo*). Por esta razão, a Hamming Loss é especialmente adequada para problemas multi-label, fornecendo uma medida direta do erro médio por rótulo.
- **Precision**: A *precision* avalia a qualidade das previsões positivas do modelo. Ou seja, mede a proporção de géneros previstos que estão realmente corretos. Um valor elevado de precision indica que o modelo comete poucos falsos positivos, ou seja, evita atribuir géneros incorretos aos livros. Modelos com alta precision tendem a ser mais conservadores nas suas previsões.
- **Recall**: O *recall* mede a capacidade do modelo em identificar todos os géneros relevantes presentes nos dados. Em outras palavras, avalia quantos dos géneros reais foram corretamente previstos. Um valor elevado de recall indica que o modelo consegue

capturar a maioria dos géneros associados a cada livro, embora possa incluir alguns erros. Modelos com alto recall tendem a ser mais permissivos.

- **F1 score**: O *F1-score* combina precision e recall numa única métrica, através da sua média harmónica. Esta métrica é particularmente útil quando se pretende um equilíbrio entre evitar falsos positivos e minimizar falsos negativos. Um F1-score elevado indica que o modelo apresenta um bom compromisso entre precisão e cobertura, sendo por isso uma das métricas mais relevantes para problemas de classificação multi-label.

Decidiu-se usar as métricas micro-averaged (para precision, recall e f1 score) porque sabe-se que há um desequilíbrio entre classes e pretendesse dar mais ênfase aos géneros mais frequentes, pois os menos frequentes são mais sujeitos a ruídos e podem prejudicar a avaliação dos modelos.

Como o âmbito do trabalho é deduzir os géneros a que pertence o livro e sendo uma solução multi-label considerou-se desnecessário avaliar métricas sobre os negativos como a Especificidade (specifity) e o valor negativo preditivo (NPV).

```
Y_probs = model.predict_proba(X_test)

thresholds = (0.5, 0.4, 0.3, 0.2, 0.1)
for threshold in thresholds:
    genre_pred = (Y_probs >= threshold).astype(int)

    hloss = hamming_loss(Y_test, genre_pred)
    acc = accuracy_score(Y_test, genre_pred)
    precision_micro = precision_score(Y_test, genre_pred, average="micro")
    recall_micro = recall_score(Y_test, genre_pred, average="micro")
    f1_micro = f1_score(Y_test, genre_pred, average="micro")
```

A análise dos resultados foi realizada considerando diferentes *thresholds de probabilidade* (0.5 a 0.1), permitindo avaliar o comportamento dos modelos em diferentes níveis de exigência na atribuição de rótulos.

Foi também calculado o threshold ideal por label com base no ponto ótimo do f1_score usando a “precision_recall_curve” do Scikit-learn. A motivação para thresholds individuais prende-se com o facto de diferentes labels apresentarem:

- Distribuições de probabilidade distintas
- Frequências diferentes (labels raros vs frequentes)
- Níveis de dificuldade distintos

```python
Y_probs = model.predict_proba(X_test)

n_labels = Y_probs.shape[1]
best_thresholds = np.zeros(n_labels)

for i in range(n_labels):
    y_true_label = Y_test[:, i]
    y_prob_label = Y_probs[:, i]

    precision, recall, thresh = precision_recall_curve(y_true_label, y_prob_label)

    f1_scores = 2 * (precision * recall) / (precision + recall + 1e-8)
    best_idx = np.argmax(f1_scores)

    best_thresholds[i] = thresh[best_idx]

np.save(f"./generated/thresholds_{model_filename_suffix}.npy", best_thresholds)

algorithm_desc = f"{vectorizer_name} + {clustering_name} + {classifier_name}"

genre_pred = (Y_probs >= best_thresholds).astype(int)

hloss = hamming_loss(Y_test, genre_pred)
acc = accuracy_score(Y_test, genre_pred)
precision_micro = precision_score(Y_test, genre_pred, average="micro")
recall_micro = recall_score(Y_test, genre_pred, average="micro")
f1_micro = f1_score(Y_test, genre_pred, average="micro")
```

Os resultados podem ser consultados em 6.4 Comparação geral de métricas e 6.3 Comparação de métricas para thresholds otimizados por género.

3.4.1. Impacto do Threshold

Observa-se um comportamento consistente em todos os modelos:

- A diminuição do threshold resulta num aumento do **recall**
- Em contrapartida, verifica-se uma diminuição da **precision**

Este comportamento evidencia o trade-off típico em problemas de classificação multi-label, onde thresholds mais baixos tornam o modelo mais permissivo, aumentando a cobertura de rótulos, mas também o número de falsos positivos.

O threshold fixo mais otimizado situa-se tipicamente no 0,3.

3.4.2. Accuracy

Os valores de accuracy são relativamente baixos (~0.03–0.04), o que é esperado em problemas multi-label, dado que esta métrica exige a previsão correta de todos os rótulos de uma instância.

3.4.3. Hamming Loss

De forma geral os modelos apresentaram bons modelos de hamming loss, com valores consistentemente abaixo de 0.05 para thresholds mais elevados.

Este resultado indica que este modelo é o mais eficaz na previsão individual de rótulos, apresentando menor taxa de erro por label.

Mas este valor não é muito fiável, porque sabemos que o sistema foi treinado com cerca de 50/60 labels e tipicamente por livro, não existe mais de 5 labels atribuídas, ou seja, todas as outras 50 são zeros, o que deduzimos que o modelo aprendeu bem a dizer que não é do género.

Verifica-se também que o Hamming Loss aumenta à medida que o threshold diminui que se justifica com o aumento do número de positivos, o que eleva a probabilidade de erro.

3.4.4 Accuracy, recall e F1 score

Uma precision elevada é boa, significa que muitos rótulos previstos estão corretos, mas isto pode dever-se ao facto de termos muitos rótulos e, geralmente, um livro ter apenas 2 ou 3 géneros, pelo que todos os outros 50/60 seriam 0. Ou seja, ele aprendeu bem a dizer quando não pertence ao género e tornou-se conservador.

Um recall baixo não é bom, isto significa que se perdem muitos géneros verdadeiros.

A alta precisão aliado ao baixo recall e baixo F1 indica que são modelos cautelosos, prevê poucas etiquetas, as que prevê estão geralmente correctas (alta precisão), mas deixa de identificar muitos géneros verdadeiros (baixo recall).

O ponto ideal encontra-se quando o threshold está a 0.2, em que os modelos são mais “ousados” e apesar de a precision diminuir, o recall aumenta mais expressivamente, o que se reflete no aumento do f1 score.

De uma forma geral o XGBoost é mais equilibrado e constante ao longo dos thresholds que a Regressão linear.

3.4.5 Comparação entre representações de texto

Contrariamente ao esperado os modelos baseados em TF-IDF superaram os baseados em SBERT na maioria dos cenários.

Possíveis justificações:

- O problema depende fortemente de palavras-chave específicas associadas aos géneros
- O dataset pode não ser suficientemente grande para tirar total proveito de embeddings contextuais
- SBERT pode suavizar diferenças importantes entre géneros

3.4.6 Avaliação de resultados para thresholds calculados por label

Após análise dos resultados obtidos com os thresholds calculados por género (label) é possível validar que o threshold por label raramente supera de forma significativa o melhor threshold global.

Isto pode ter várias causas:

1 De uma forma geral o modelo já está bem calibrado;
2 As labels têm demasiada heterogeneidade, ao nível das ocorrências e ao nível da dificuldade, pois géneros que implicam subjetividade (ex. comédia) são mais difíceis de detetar que géneros concretos (ex. romance);
3 Pode ter ocorrido um overfitting no cálculo dos thresholds e ter-se adaptada demasiado ao ruído.

3.4.7 Comparação global da solução

A solução que utiliza TFIDF + Hierarchical Clustering + XGBoost revelou-se a solução mais equilibrada em termos de F1-Score (0.6314) e Precision (0.6141). No entanto, para aplicações práticas multilingues, a arquitetura SBERT é a recomendada pela sua robustez na inferência, como demonstrado nos testes manuais.

3.5 Utilização dos modelos

Por fim, os modelos foram usados em textos livres de forma a validar manualmente a sua eficácia e a sua usabilidade em ambientes produtivos. Usou-se um threshold otimizado por género. Ver resultados em 6.5 Testes de inferência com valores manuais

```python
threshold = 0.3

# vectorizer = "TFIDF"
vectorizer = "SBERT"

texts = (
    "London, 1888. Beneath the fog-filled streets and flickering gas lamps, the city whispers with rumors of a series of strange disa
    "In a distant future where advanced technology has unlocked portals to forgotten realms, humanity discovers a hidden universe fil
    "The Parker family just wanted a peaceful weekend getaway in the countryside. Instead, they end up renting an old mansion that th
    "Lena never believed in fate. As a determined art student trying to balance college, part-time jobs, and her dreams of becoming a
    "For as long as they can remember, five friends have shared one strange thing in common: absolutely terrible luck.\nThere's Jake,
    "Num reino onde a magia é proibida e as estrelas são vistas como presságios de desgraça, Elara esconde um segredo que pode mudar
)
# # texts_vectors = vectorize_descriptions_with_tfidf(texts)
texts_vectors = vectorize_descriptions_with_sbert(texts, use_file=False)

# clustering = "HierarchicalClustering"
clustering = "HDBSCAN"

# classifier = "LogisticRegression"
# classifier = "SVM"
classifier = "XGBoost"


model = joblib.load(f"./generated/genre_classifier_{vectorizer}_{clustering}_{classifier}.joblib")
mlb = joblib.load(f"./generated/mlb_{vectorizer}_{clustering}.joblib")
thresholds = np.load(f"./generated/thresholds_{vectorizer}_{clustering}_{classifier}.npy")
print("Model loaded successfully.")


# Predict probabilities
genre_pred = model.predict_proba(texts_vectors)

for i, probs in enumerate(genre_pred):
    print(f"Book {i+1} genre probabilities:")
    for j, genre in enumerate(mlb.classes_):
        if probs[j] >= thresholds[j]:
            print(f" {genre}: {probs[j]:.4f}")
```

4 Conclusões finais e trabalho futuro

- O uso de XGBoost melhora o desempenho face à Regressão Logística, sendo mais equilibrado (melhor F1 score e melhor hamming loss) ao longo dos thresholds;
- TF-IDF continua altamente competitivo, especialmente em tarefas baseadas em palavras-chave;
- O ajuste do threshold é crucial em problemas multi-label. Neste caso, deveria ser feita melhor reflexão sobre as causa do threshold calculado por label não apresentar resultados significativos;
- Diferentes métricas levam a conclusões diferentes, sendo o F1-score a mais equilibrada;
- Existe um grande desequilíbrio de frequência entre géneros;
- Custo computacional elevado para embeddings contextuais.
- SBERT generalista utilizado não é otimizado para o problema;

5 Tecnologias Utilizadas

- Python
- Pandas / NumPy
- Scikit-learn (Regressão Logística, SVM, Tf-idf, métricas, divisão de dados)
- SciPy (clustering hierárquico)
- XGBoost
- Sentence-BERT (multilingual)
- NLTK
- Jupyter Notebook
- FastText
- UMAP
- HDBscan

```python
from fast_langdetect import detect
import hdbscan
import joblib
import matplotlib.pyplot as plt
import nltk
from nltk.corpus import stopwords
from nltk.stem import WordNetLemmatizer
from nltk.tokenize import word_tokenize
import numpy as np
import pandas as pd
from pathlib import Path
import re
from scipy.cluster.hierarchy import linkage, dendrogram, fcluster
from sentence_transformers import SentenceTransformer
from sklearn.calibration import CalibratedClassifierCV
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import hamming_loss, accuracy_score, f1_score, precision_score, recall_score
from sklearn.model_selection import train_test_split
from sklearn.multiclass import OneVsRestClassifier
from sklearn.preprocessing import MultiLabelBinarizer
from sklearn.svm import LinearSVC
import torch
import umap # umap-learn
import unicodedata
from xgboost import XGBClassifier

nltk.download('punkt')
nltk.download('punkt_tab')
nltk.download('stopwords')
nltk.download('wordnet')

stop_words = set(stopwords.words('english'))
lemmatizer = WordNetLemmatizer()

device = "cuda" if torch.cuda.is_available() else "cpu"
print(f"Using device: {device}")
```

✓ 39.8s

```
d:\diogo\Desktop\MsEx IA apl\LLMs\aulas\torch-env\Lib\site-packages\tqdm\auto.py:21: TqdmWarning: IProgress not f
  from .autonotebook import tqdm as notebook_tqdm
Using device: cuda
```

6 Anexos

6.1 Código do trabalho realizado:

https://github.com/diogosantosmendes/executivemaster_pln/blob/main/tp2.ipynb

6.2 Documentos gerados durante a execução:

book_desc_embeddings_sbert.npy	24/03/2026 23:22	NPY File	98 005 KB
book_desc_vectorizer_tfidf.joblib	24/03/2026 18:49	JOBLIB File	180 KB
genre_classifier_SBERT_HDBSCAN_LogisticRegression.joblib	24/03/2026 23:23	JOBLIB File	275 KB
genre_classifier_SBERT_HDBSCAN_SVM.joblib	24/03/2026 23:33	JOBLIB File	1 402 KB
genre_classifier_SBERT_HDBSCAN_XGBoost.joblib	30/03/2026 18:44	JOBLIB File	83 877 KB
genre_classifier_SBERT_HierarchicalClustering_LogisticRegression.joblib	24/03/2026 23:34	JOBLIB File	219 KB
genre_classifier_SBERT_HierarchicalClustering_SVM.joblib	24/03/2026 23:44	JOBLIB File	1 113 KB
genre_classifier_SBERT_HierarchicalClustering_XGBoost.joblib	30/03/2026 18:26	JOBLIB File	78 952 KB
genre_classifier_TFIDF_HDBSCAN_LogisticRegression.joblib	24/03/2026 20:16	JOBLIB File	2 681 KB
genre_classifier_TFIDF_HDBSCAN_SVM.joblib	24/03/2026 20:23	JOBLIB File	13 435 KB
genre_classifier_TFIDF_HDBSCAN_XGBoost.joblib	24/03/2026 21:32	JOBLIB File	55 094 KB
genre_classifier_TFIDF_HierarchicalClustering_LogisticRegression.joblib	24/03/2026 22:37	JOBLIB File	1 972 KB
genre_classifier_TFIDF_HierarchicalClustering_SVM.joblib	24/03/2026 22:41	JOBLIB File	9 879 KB
genre_classifier_TFIDF_HierarchicalClustering_XGBoost.joblib	30/03/2026 19:35	JOBLIB File	44 317 KB
genre_to_label_SBERT_HDBSCAN.joblib	24/03/2026 23:22	JOBLIB File	28 KB
genre_to_label_SBERT_HierarchicalClustering.joblib	24/03/2026 23:33	JOBLIB File	25 KB
genre_to_label_TFIDF_HDBSCAN.joblib	24/03/2026 20:12	JOBLIB File	27 KB
genre_to_label_TFIDF_HierarchicalClustering.joblib	24/03/2026 22:34	JOBLIB File	24 KB
mlb_SBERT_HDBSCAN.joblib	24/03/2026 23:22	JOBLIB File	2 KB
mlb_SBERT_HierarchicalClustering.joblib	24/03/2026 23:33	JOBLIB File	2 KB
mlb_TFIDF_HDBSCAN.joblib	24/03/2026 20:12	JOBLIB File	2 KB
mlb_TFIDF_HierarchicalClustering.joblib	24/03/2026 22:34	JOBLIB File	2 KB
results.bck.csv	31/03/2026 21:25	Microsoft Excel C...	5 KB
results_optimized.bck.csv	30/03/2026 22:31	Microsoft Excel C...	4 KB
thresholds_SBERT_HDBSCAN_LogisticRegression.npy	30/03/2026 22:27	NPY File	1 KB
thresholds_SBERT_HDBSCAN_SVM.npy	30/03/2026 22:27	NPY File	1 KB
thresholds_SBERT_HDBSCAN_XGBoost.npy	30/03/2026 22:28	NPY File	1 KB
thresholds_SBERT_HierarchicalClustering_LogisticRegression.npy	30/03/2026 22:28	NPY File	1 KB
thresholds_SBERT_HierarchicalClustering_SVM.npy	30/03/2026 22:28	NPY File	1 KB
thresholds_SBERT_HierarchicalClustering_XGBoost.npy	30/03/2026 22:28	NPY File	1 KB
thresholds_TFIDF_HDBSCAN_LogisticRegression.npy	30/03/2026 22:29	NPY File	1 KB
thresholds_TFIDF_HDBSCAN_SVM.npy	30/03/2026 22:29	NPY File	1 KB
thresholds_TFIDF_HDBSCAN_XGBoost.npy	30/03/2026 22:30	NPY File	1 KB
thresholds_TFIDF_HierarchicalClustering_LogisticRegression.npy	30/03/2026 22:30	NPY File	1 KB
thresholds_TFIDF_HierarchicalClustering_SVM.npy	30/03/2026 22:31	NPY File	1 KB
thresholds_TFIDF_HierarchicalClustering_XGBoost.npy	30/03/2026 22:31	NPY File	1 KB

6.3 Comparação de métricas para thresholds otimizados por género

Algorithms	Hamming Loss	Accuracy	Precision	Recall	F1 Score
SBERT + HDBSCAN + LogisticRegression	0,0615	0,0336	0,4812	0,6732	0,5613
SBERT + HDBSCAN + SVM	0,0501	0,0523	0,5613	0,6568	0,6053
SBERT + HDBSCAN + XGBoost	0,0480	0,0682	0,5782	0,6620	0,6173
SBERT + HierarchicalClustering + LogisticRegression	0,0689	0,0372	0,5445	0,6520	0,5934
SBERT + HierarchicalClustering + SVM	0,0635	0,0491	0,5775	0,6593	0,6157
SBERT + HierarchicalClustering + XGBoost	0,0614	0,0666	0,5921	0,6548	0,6219
TFIDF + HDBSCAN + LogisticRegression	0,0451	0,0581	0,5865	0,6772	0,6286
TFIDF + HDBSCAN + SVM	0,0440	0,0660	0,5997	0,6611	0,6289
TFIDF + HDBSCAN + XGBoost	0,0630	0,0114	0,4595	0,6628	0,5428
TFIDF + HierarchicalClustering + LogisticRegression	0,0592	0,0644	0,5996	0,6658	0,6310
TFIDF + HierarchicalClustering + SVM	0,0584	0,0721	0,6083	0,6509	0,6288
TFIDF + HierarchicalClustering + XGBoost	0,0577	0,0702	0,6141	0,6498	0,6314

6.4 Comparação geral de métricas

Algorithms	Hamming Loss						Accuracy						Precision						Recall						F1 Score					
	0,5	0,4	0,3	0,2	0,1	per label	0,5	0,4	0,3	0,2	0,1	per label	0,5	0,4	0,3	0,2	0,1	per label	0,5	0,4	0,3	0,2	0,1	per label	0,5	0,4	0,3	0,2	0,1	per label
SBERT + HDBSCAN + LogisticRegression	0,0411	0,0420	0,0456	0,0556	0,0881	0,0615	0,0876	0,0834	0,0613	0,0263	0,0016	0,0336	0,7406	0,6793	0,6090	0,5181	0,3818	0,4812	0,4567	0,5335	0,6142	0,7046	0,8209	0,6732	0,5650	0,5976	0,6116	0,5972	0,5212	0,5613
SBERT + HDBSCAN + SVM	0,0404	0,0413	0,0447	0,0540	0,0853	0,0501	0,0946	0,0873	0,0663	0,0312	0,0026	0,0523	0,7411	0,6840	0,6169	0,5282	0,3906	0,5613	0,4744	0,5450	0,6210	0,7063	0,8194	0,6568	0,5785	0,6067	0,6190	0,6044	0,5290	0,6053
SBERT + HDBSCAN + XGBoost	0,0401	0,0402	0,0418	0,0466	0,0616	0,0480	0,1057	0,1047	0,0914	0,0632	0,0170	0,0682	0,7635	0,7154	0,6615	0,5925	0,4824	0,5782	0,4554	0,5193	0,5820	0,6506	0,7447	0,6620	0,5705	0,6017	0,6192	0,6202	0,5855	0,6173
SBERT + HierarchicalClustering + LogisticRegression	0,0538	0,0549	0,0595	0,0723	0,1148	0,0689	0,0812	0,0762	0,0556	0,0236	0,0016	0,0372	0,7449	0,6845	0,6137	0,5233	0,3855	0,5445	0,4590	0,5344	0,6142	0,7056	0,8234	0,6520	0,5680	0,6002	0,6140	0,6009	0,5252	0,5934
SBERT + HierarchicalClustering + SVM	0,0530	0,0539	0,0584	0,0702	0,1107	0,0635	0,0867	0,0813	0,0593	0,0277	0,0019	0,0491	0,7458	0,6907	0,6212	0,5335	0,3953	0,5775	0,4739	0,5443	0,6203	0,7069	0,8222	0,6593	0,5795	0,6088	0,6207	0,6081	0,5339	0,6157
SBERT + HierarchicalClustering + XGBoost	0,0525	0,0526	0,0545	0,0604	0,0793	0,0614	0,0998	0,1007	0,0836	0,0562	0,0168	0,0666	0,7710	0,7239	0,6699	0,6000	0,4906	0,5921	0,4538	0,5140	0,5766	0,6494	0,7456	0,6548	0,5713	0,6011	0,6197	0,6237	0,5918	0,6219
TFIDF + HDBSCAN + LogisticRegression	0,0373	0,0367	0,0388	0,0462	0,0747	0,0451	0,0881	0,0886	0,0774	0,0424	0,0024	0,0581	0,7925	0,7426	0,6711	0,5742	0,4171	0,5865	0,4589	0,5357	0,6118	0,7003	0,8164	0,6772	0,5812	0,6224	0,6401	0,6310	0,5522	0,6286
TFIDF + HDBSCAN + SVM	0,0371	0,0372	0,0400	0,0488	0,0797	0,0440	0,0932	0,0961	0,0797	0,0423	0,0048	0,0660	0,7717	0,7194	0,6488	0,5524	0,3992	0,5997	0,4855	0,5586	0,6328	0,7128	0,8182	0,6611	0,5960	0,6289	0,6407	0,6224	0,5366	0,6289
TFIDF + HDBSCAN + XGBoost	0,0377	0,0376	0,0398	0,0477	0,0773	0,0630	0,0791	0,0834	0,0678	0,0331	0,0028	0,0114	0,7754	0,7230	0,6568	0,5622	0,4068	0,4595	0,4674	0,5408	0,6175	0,6989	0,8068	0,6628	0,5832	0,6188	0,6366	0,6231	0,5409	0,5428
TFIDF + HierarchicalClustering + LogisticRegression	0,0506	0,0501	0,0528	0,0634	0,1041	0,0592	0,0854	0,0941	0,0826	0,0383	0,0024	0,0644	0,7931	0,7376	0,6665	0,5672	0,4083	0,5996	0,4524	0,5295	0,6122	0,7044	0,8231	0,6658	0,5762	0,6165	0,6382	0,6284	0,5459	0,6310
TFIDF + HierarchicalClustering + SVM	0,0507	0,0510	0,0548	0,0676	0,1115	0,0584	0,0933	0,0953	0,0806	0,0385	0,0037	0,0721	0,7698	0,7132	0,6428	0,5424	0,3893	0,6083	0,4751	0,5505	0,6278	0,7120	0,8203	0,6509	0,5876	0,6214	0,6352	0,6158	0,5280	0,6288
TFIDF + HierarchicalClustering + XGBoost	0,0513	0,0514	0,0544	0,0654	0,1070	0,0577	0,0796	0,0843	0,0736	0,0325	0,0020	0,0702	0,7779	0,7205	0,6521	0,5556	0,3997	0,6141	0,4550	0,5294	0,6108	0,6972	0,8111	0,6498	0,5741	0,6103	0,6308	0,6184	0,5355	0,6314

6.5 Testes de inferência com valores manuais

Algorithms	Desc 1	Desc 2	Desc 3	Desc 4	Desc 5	Desc 6
SBERT + HDBSCAN + LogisticRegression	Classics: 0.4890 European Literature: 0.5555 Fantasy: 0.5123 Fiction: 0.9050 Harlequin: 0.0013 Literature: 0.5704 Mystery: 0.7035 Steampunk: 0.0933 Thriller: 0.4657	Fantasy: 0.9777 Fiction: 0.8338 Young Adult: 0.4293	Childrens: 0.3200 Fantasy: 0.4295 Fiction: 0.8032 Middle Grade: 0.1592 Mystery: 0.8328 Thriller: 0.3614	Fiction: 0.5668 Romance: 0.7994 Young Adult: 0.4558	Adventure: 0.1739 Childrens: 0.3528 Fiction: 0.7813 Harlequin: 0.0013 Mystery: 0.5612 Thriller: 0.2940 Young Adult: 0.3580	Dragons: 0.1802 Fantasy: 0.9973 Fiction: 0.6935 Magic: 0.6882 Young Adult: 0.7296
SBERT + HDBSCAN + SVM	Classics: 0.4921 European Literature: 0.5318 Fantasy: 0.4706 Fiction: 0.9173 Literature: 0.5649 Mystery: 0.7948 Thriller: 0.4595	Fantasy: 0.9798 Fiction: 0.8442 Young Adult: 0.4425	Childrens: 0.3828 Fiction: 0.7198 Mystery: 0.8693 Thriller: 0.2760	Fiction: 0.5843 Romance: 0.8310 Young Adult: 0.4568	Adventure: 0.2610 Childrens: 0.3023 Fiction: 0.7989 Middle Grade: 0.1853 Mystery: 0.4943 Young Adult: 0.4261	Dragons: 0.1502 Fantasy: 0.9980 Fiction: 0.6963 Magic: 0.6928 Young Adult: 0.7442
SBERT + HDBSCAN + XGBoost	Classics: 0.4204 Cultural: 0.1426 Fiction: 0.8591 Historical: 0.3243 Literature: 0.3322 Mystery: 0.3574 Thriller: 0.2642	Fantasy: 0.9779 Fiction: 0.8276 Steampunk: 0.0626	Childrens: 0.1846 Fantasy: 0.5093 Fiction: 0.8355 Mystery: 0.6419 Thriller: 0.2138	Fantasy: 0.3801 Fiction: 0.5939 Romance: 0.7804 Young Adult: 0.4131	Fiction: 0.8112 Mystery: 0.5473	Dragons: 0.0961 Fantasy: 0.9915 Fiction: 0.5066 Magic: 0.2403 Young Adult: 0.4235
SBERT + HierarchicalClustering + LogisticRegression	Classics: 0.4427 Fantasy: 0.9034 Fiction: 0.8604 France: 0.2176 Harlequin: 0.0013 Light Novel: 0.0014 Literature: 0.7028 Other: 0.1777 Science Fiction: 0.5268 Sequential Art: 0.2828 Steampunk: 0.0655	Fantasy: 0.9630 Fiction: 0.6553 Light Novel: 0.0013 Other: 0.2187 Science Fiction: 0.9318 Steampunk: 0.1647 Young Adult: 0.4323	Fantasy: 0.8938 Fiction: 0.8160 Gothic: 0.1094 Middle Grade: 0.1592 Other: 0.1407	Contemporary: 0.4474 Fiction: 0.5359 Romance: 0.7346 Young Adult: 0.3337	Adventure: 0.1609 Contemporary: 0.3921 Fantasy: 0.7048 Fiction: 0.7463 Harlequin: 0.0013 Young Adult: 0.6419	Fantasy: 0.9910 Fiction: 0.6291 Science Fiction: 0.3540 Young Adult: 0.6555

SBERT + HierarchicalClustering + SVM	19th Century: 0.1174 Classics: 0.4184 Fantasy: 0.9165 Fiction: 0.8649 Literature: 0.6405 Science Fiction: 0.6497 Sequential Art: 0.2506 Steampunk: 0.2272	Fantasy: 0.9672 Fiction: 0.7118 Science Fiction: 0.9727 Space: 0.1262 Young Adult: 0.4753	Fantasy: 0.8822 Fiction: 0.7481	Contemporary: 0.5059 Fiction: 0.5636 Romance: 0.7789	Adventure: 0.2593 Contemporary: 0.3704 Fantasy: 0.7067 Fiction: 0.7626 Middle Grade: 0.1853 Young Adult: 0.6950	Fantasy: 0.9926 Fiction: 0.6287 Science Fiction: 0.3570 Young Adult: 0.6721
SBERT + HierarchicalClustering + XGBoost	Classics: 0.3145 Cultural: 0.2724 Fantasy: 0.7484 Fiction: 0.8367 Literature: 0.4992 Steampunk: 0.0299 Travel: 0.0208	Fantasy: 0.9790 Fiction: 0.7609 Science Fiction: 0.9614 Space: 0.0109 Steampunk: 0.0799 Young Adult: 0.3762	Fantasy: 0.8684 Fiction: 0.6829 Gothic: 0.0040 Young Adult: 0.4744	Fantasy: 0.5037 Fiction: 0.7037 Romance: 0.7908 Sequential Art: 0.3101 Young Adult: 0.4565	Fantasy: 0.5933 Fiction: 0.7070 Young Adult: 0.5566	Fantasy: 0.9902 Young Adult: 0.5205
TFIDF + HDBSCAN + LogisticRegression	Fantasy: 0.6762 Fiction: 0.7943 Harlequin: 0.0009 Mystery: 0.7533 Young Adult: 0.4649	Adventure: 0.3598 Fantasy: 0.9797 Fiction: 0.9310 Science Fiction Fantasy: 0.2215	Fantasy: 0.7086 Fiction: 0.8392 Humor: 0.1646 Mystery: 0.6845 Young Adult: 0.5502	Contemporary: 0.4292 Harlequin: 0.0009 Novels: 0.1322 Romance: 0.7933 Young Adult: 0.4662	Contemporary: 0.4706 Fiction: 0.7811 Middle Grade: 0.1395 Young Adult: 0.6778	Anthropology: 0.0031 Architecture: 0.0008 Classics: 0.2830 Cultural: 0.4385 Fiction: 0.6591 France: 0.3811 Harlequin: 0.0010 Historical: 0.3772 Literature: 0.2721 Sex Work: 0.0002 World War II: 0.1636
TFIDF + HDBSCAN + SVM	Fantasy: 0.7855 Fiction: 0.7656 Mystery: 0.8844 Young Adult: 0.4253	Adventure: 0.2977 Fantasy: 0.9917 Fiction: 0.9309	Fantasy: 0.8324 Fiction: 0.8650 Humor: 0.2482 Middle Grade: 0.1695 Mystery: 0.7140 Novels: 0.2336 Young Adult: 0.6957	Audiobook: 0.1409 Contemporary: 0.4539 Novels: 0.1961 Romance: 0.8425 Young Adult: 0.6528	Contemporary: 0.4294 Fiction: 0.7780 Humor: 0.1800 Young Adult: 0.5367	Architecture: 0.0254 Cultural: 0.3911 Fiction: 0.6236 France: 0.3095 Historical: 0.3686 World War II: 0.2287

TFIDF + HDBSCAN + XGBoost	Fantasy: 0.5067 Fiction: 0.7801 International Relations: 0.0000 Sex Work: 0.0002 Young Adult: 0.3893	Comics: 0.4531 Fantasy: 0.9667 Fiction: 0.8411 International Relations: 0.0000 Novels: 0.1390 Science Fiction Fantasy: 0.6925 Sequential Art: 0.3340 Sex Work: 0.0002	Architecture: 0.1213 Fantasy: 0.8236 Fiction: 0.7530 International Relations: 0.0000 Mystery: 0.8362 Sex Work: 0.0002	Contemporary: 0.2774 International Relations: 0.0005 Romance: 0.5304 Sequential Art: 0.3033 Sex Work: 0.0002	Contemporary: 0.4734 Fiction: 0.7451 Middle Grade: 0.1547 Mystery: 0.4691 Sex Work: 0.0001 Young Adult: 0.6694	Fiction: 0.6104 International Relations: 0.0000 Sex Work: 0.0002
TFIDF + HierarchicalClustering + LogisticRegression	Fantasy: 0.6708 Fiction: 0.8390 Harlequin: 0.0009 Mystery: 0.6510 Young Adult: 0.4348	Adventure: 0.3892 Fantasy: 0.9838 Fiction: 0.9646 Magic: 0.2680	Childrens: 0.4675 Fantasy: 0.7460 Fiction: 0.8053 Mystery: 0.6547	Contemporary: 0.4250 Harlequin: 0.0009 Romance: 0.8804 Young Adult: 0.5311	Contemporary: 0.4608 Fiction: 0.7018 Middle Grade: 0.1395 Young Adult: 0.5337	19th Century: 0.1224 Classics: 0.2961 Cultural: 0.4484 Fiction: 0.7021 France: 0.3634 Harlequin: 0.0010 Historical: 0.4255 Literature: 0.2777
TFIDF + HierarchicalClustering + SVM	Fantasy: 0.8199 Fiction: 0.8293 Mystery: 0.8218 Young Adult: 0.3680	Adventure: 0.3116 Fantasy: 0.9915 Fiction: 0.9729 Magic: 0.1983	Childrens: 0.5371 Fantasy: 0.8442 Fiction: 0.8226 Middle Grade: 0.1695 Mystery: 0.5989 Young Adult: 0.4253	Audiobook: 0.1409 Contemporary: 0.4664 Nonfiction: 0.3944 Romance: 0.9314 Young Adult: 0.7268	Contemporary: 0.4133 Fiction: 0.7273 Humor: 0.2193	19th Century: 0.1107 Cultural: 0.3843 Fiction: 0.6656 France: 0.2670 Historical: 0.4294 Romance: 0.3380
TFIDF + HierarchicalClustering + XGBoost	Fantasy: 0.4663 Fiction: 0.7939	Adventure: 0.3010 Fantasy: 0.9774 Fiction: 0.8788 Graphic Novels: 0.4370 Magic: 0.2748 Sequential Art: 0.3533	Childrens: 0.4908 Fantasy: 0.8359 Fiction: 0.7907 Mystery: 0.7719	Nonfiction: 0.3800 Romance: 0.5224 Sequential Art: 0.2636	Childrens: 0.2514 Contemporary: 0.3508 Fiction: 0.8083 Middle Grade: 0.1547 Mystery: 0.3801 Travel: 0.1621 Young Adult: 0.6892	Fiction: 0.5857

6.5.1 Textos para testes de inferência

Desc 1	Historical, Mystery
London, 1888. Beneath the fog-filled streets and flickering gas lamps, the city whispers with rumors of a series of strange disappearances. Each vanished person was last seen near the same narrow alley in Whitechapel—and each left behind an identical object: a small, intricately crafted pocket watch that always stops at exactly 3:17 a.m.	

Desc 2	Fantasy, Science Fiction
In a distant future where advanced technology has unlocked portals to forgotten realms, humanity discovers a hidden universe filled with ancient magic and mythical creatures. When a young astrophysicist accidentally activates a long-dormant gateway orbiting Earth, she unleashes a mysterious force that begins merging science and sorcery.	
Desc 3	Horror, Family
The Parker family just wanted a peaceful weekend getaway in the countryside. Instead, they end up renting an old mansion that the locals refuse to talk about. According to the listing, the house is “full of character.” What it doesn’t mention is that the character includes a grumpy ghost, a mischievous shadow creature, and a cursed doll that really hates loud children.	
Desc 4	Romance, Young Adults
Lena never believed in fate. As a determined art student trying to balance college, part-time jobs, and her dreams of becoming a painter, she’s convinced life is all about hard work—not destiny. Then she literally collides with Noah. Noah is a quiet but thoughtful engineering student who prefers books and late-night coffee over crowded parties. When Lena accidentally spills an entire cup of coffee over his carefully organized notes in a campus café, their first meeting is anything but romantic.	
Desc 5	Comedia
For as long as they can remember, five friends have shared one strange thing in common: absolutely terrible luck.\nThere’s Jake, who once slipped on a banana peel… in a parking lot… where there were no bananas.\nMaya, whose phone always dies exactly when something important happens.\nLuis, who somehow sets off alarms in stores even when he doesn’t buy anything.\nSophie, whose GPS constantly sends the group to the wrong places.\nAnd Ben, who has broken six chairs in his life just by sitting down.\nDespite their ridiculous streak of misfortune, they decide to finally do something exciting together: a weekend road trip to attend a huge festival.	
Desc 6	Romance, Fantasy, Portuguese
Num reino onde a magia é proibida e as estrelas são vistas como presságios de desgraça, Elara esconde um segredo que pode mudar tudo: ela consegue ouvir o sussurro do céu.\nQuando conhece Kael, um misterioso viajante com um passado envolto em sombras, o destino de ambos entrelaça-se de forma inesperada. À medida que forças antigas despertam e uma guerra se aproxima, Elara e Kael são obrigados a confiar um no outro para sobreviver.	